

IRIS Production Guardian — Roteiro de Gravação V2

Roteiro de gravação — vídeo de apresentação (V2)

Passo a passo operacional **auto-suficiente** para o proprietário gravar sozinho: todo comando a rodar, toda URL a abrir (ou menu a clicar) e toda fala sugerida estão neste único documento — não é preciso abrir nenhum outro arquivo durante a gravação.

V2 (18/09/2026) — revisão a pedido do proprietário, `Ajustes.txt` itens 6 a 6.7: (1) abertura com fala exata sobre os três módulos; (2) todo comando de terminal que é uma única chamada `docker exec` agora está numa única linha física, sem quebra por `\`, para colar sem risco de o terminal interpretar errado; comandos que são de fato vários passos separados aparecem numerados; (3) fala detalhada, primeira pessoa, sem pressupor conhecimento de interoperability, para comparar o Monitor antes/depois da falha; (4) toda instrução de navegação dentro da própria aplicação agora diz qual item clicar no menu lateral, não o nome físico da classe/URL; (5) abrir o Business Rule Editor ganhou o caminho de cliques exato dentro do Management Portal, com screenshot anotado, porque **o parâmetro `?RULE=...` na URL não carrega o diagrama sozinho** — é preciso clicar em “Open” e navegar o diálogo, isso foi testado ao vivo nesta revisão — e a fala sobre busca híbrida ficou detalhada; (6) encerramento com fala exata e todos os links necessários. O documento `08_ROTUIRO_GRAVACAO_VIDEO.md` original foi mantido sem alteração; este arquivo é a versão para usar na gravação.

Login usado em toda a aplicação e no Management Portal: `guardian` / `guardian`.

Convenção de comandos de terminal usada neste documento (item 6.3 de `Ajustes.txt`): todo bloco de código abaixo marcado como “comando único” é uma única linha física — copie a linha inteira (mesmo que o seu terminal quebre a exibição em duas linhas visuais) e cole de uma vez só. Nunca reconstrua o comando digitando `\` no fim de uma linha. Blocos marcados como “heredoc” (`<<'EOF' ... EOF`) também devem ser colados inteiros de uma vez — o terminal só executa depois de ver o `EOF` final, então colar várias linhas de um heredoc de uma vez é seguro e esperado. Quando há mais de um comando separado dentro do mesmo passo, eles vêm numerados (1, 2, 3...), cada um no seu próprio bloco.

Navegação dentro da aplicação (item 6.5): depois do primeiro login, nunca é preciso digitar outra URL de página da aplicação — use sempre os links do menu lateral esquerdo, que têm estes nomes exatos (interface em inglês, requisito do concurso):

Clique no menu lateral	Abre
Monitor	Production Monitor
Investigator	AI Incident Investigator
RAG Assistant (Gemini)	RAG Assistant, provedor Gemini
RAG Assistant (Groq)	RAG Assistant, provedor Groq

URLs de referência (só a primeira, do Monitor, precisa ser digitada — é a porta de entrada; ajuste a porta se o container publicar em outra, confira com `docker port iris-guardian`):

`http://localhost:53773/csp/guardian/Guardian.UI.MonitorPage.cls`

Tela	Como chegar
Production Monitor	Primeira URL a abrir (acima), depois sempre pelo menu Monitor

Tela	Como chegar
AI Incident Investigator	Menu lateral esquerdo → Investigator
RAG Assistant (Gemini)	Menu lateral esquerdo → RAG Assistant (Gemini)
RAG Assistant (Groq)	Menu lateral esquerdo → RAG Assistant (Groq)
Management Portal (home)	<code>http://localhost:53773/csp/sys/UtilHome.csp</code>
Production Configuration	Management Portal → menu esquerdo Interoperability → Configure → Production
Message Viewer	Management Portal → menu esquerdo Interoperability → View → Messages
Business Rule Editor	Management Portal → menu esquerdo Interoperability → Build → Business Rules (ver seção 7, caminho exato com screenshot)

Todos os comandos de terminal abaixo rodam no seu Mac (Terminal.app ou iTerm), **não** dentro do container — eles chamam `docker exec` por fora.

0. Antes de gravar

- ☐ Fechar todas as abas/janelas com dados pessoais (e-mail, favoritos do navegador, outras abas do sistema operacional). Screenshots anteriores deste projeto já vazaram a barra de favoritos do navegador sem querer — **ocultar a barra de favoritos/abas antes de gravar** (ou usar uma janela anônima sem favoritos salvos).
- ☐ Confirmar que nenhuma chave de API (Gemini, Groq) vai aparecer na tela — elas ficam em `Ens.Config.Credentials`, tela que você não abre em nenhum passo deste roteiro (fica em Interoperability → Configure → Credentials no Management Portal). Só não abra essa tela específica e está seguro.
- ☐ Subir o container, se ainda não estiver rodando:

```
docker start iris-guardian
```

- ☐ Confirmar que a Production está **Running** (heredoc — cole as 5 linhas de uma vez, do `docker exec` até o `EOF` final):

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
write ##class(Ens.Director).GetProductionStatus(.tName,.tState),!
write "Nome: ",tName," Estado: ",tState,!
halt
EOF
```

Se `Estado` não for `1` (Running), rodar isto antes de continuar (`RecoverProduction()` não recebe argumento nenhum — passar o nome da Production dá erro `<PARAMETER>`):

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
set sc=##class(Ens.Director).RecoverProduction()
write "Recover sc: ",sc,!
set sc=##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction")
write "Start sc: ",sc,!
halt
EOF
```

- ☐ Deixar os diretórios de mensagens em estado limpo (comando único):

```
docker exec -i iris-guardian sh -c 'D=/durable/guardian; rm -f $D/in/* $D/archive/* $D/out/* $D/out_priority/* && chmod 755 $D/out $D/out_priority'
```

- ☐ Deixar uma segunda janela de terminal pronta (split de tela ou picture-in-picture) — é nela que o loop de tráfego contínuo da seção 2 vai rodar, visível do início ao fim da gravação.
- ☐ **Dar um refresh forçado no navegador** antes de começar (Chrome no Mac: botão direito no ícone de recarregar com o DevTools aberto → “Esvaziar cache e atualização forçada”, ou Cmd+Shift+R). A UI recebeu ajustes de CSS em 17/09/2026 (loader, logo); um cache antigo pode mostrar a logo do loader gigante/cortada em vez do badge pequeno e elegante.
- ☐ No canto superior da sidebar da aplicação, clicar no botão de idioma até ficar **EN** (requisito do concurso: interface em inglês na gravação). Confirmar que título da aba do navegador também mudou para inglês em cada página que for abrir.
- ☐ Decidir se vai gravar com narração ao vivo ou legendas/dublagem depois — cada passo abaixo já tem uma frase pronta para narrar ou legendar.
- ☐ Fazer **um ensaio completo sem gravar** primeiro, do início ao fim, cronometrando. Corrigir qualquer trava antes da tomada real.

1. Abertura (30-60s)

Tela: slide simples (ver prompt de geração abaixo, opcional), ou a própria home/sidebar da aplicação já logada (primeira URL da tabela acima), parada, antes de navegar.

Fala sugerida (dizer com estas palavras, ou adaptar mantendo o conteúdo):

"Este é o IRIS Production Guardian, uma aplicação que construí inteiramente sobre a plataforma InterSystems IRIS para resolver um problema real de operação: quando algo falha num ambiente de integração, alguém precisa entender o que aconteceu, rápido, e não pode simplesmente confiar numa resposta genérica.

A aplicação tem três módulos. O primeiro é o **Production Monitor**, que mostra em tempo real o estado de cada host da produção — se está saudável, degradado ou fora do ar — e quantas mensagens estão passando por cada um.

O segundo é o **AI Incident Investigator**. Quando um componente falha, eu seleciono o componente e uma janela de tempo, e a IA analisa os dados reais da falha e monta uma investigação estruturada: o que os dados mostram, qual é a hipótese mais provável da causa, e o que não dá para afirmar com certeza. Ela nunca corrige nada sozinha — a decisão de agir continua sendo minha.

O terceiro é o **RAG Assistant**, que responde perguntas sobre a documentação do próprio projeto citando a fonte real, e se recusa a responder quando não tem informação suficiente, em vez de inventar uma resposta. Implementei duas versões, uma com Gemini e outra com Groq, para mostrar que a arquitetura funciona com mais de um provedor de IA.

Tudo isso roda sobre o InterSystems IRIS: a produção de interoperabilidade, o armazenamento vetorial da busca híbrida, e a orquestração dos três módulos."

1.1 Prompt para gerar o slide/fluxo de abertura (opcional, item 6.1.1)

Se quiser um slide visual em vez de (ou antes de) mostrar a aplicação parada, use o prompt abaixo numa IA geradora de imagem (Gemini, ChatGPT, Ideogram etc.). Ele já usa as cores reais da identidade visual da aplicação (`assets/css/iris-guardian-theme.css`), para o slide combinar com a UI que aparece no resto do vídeo:

```
Design a single widescreen (16:9, 1920x1080) title slide for the opening of a product demo video called "IRIS Production Guardian", built on InterSystems IRIS. Style: clean, modern, minimal enterprise SaaS dashboard aesthetic, flat design, soft shadows, rounded rectangles, no photorealism, no stock-photo people, no watermarks.

Color palette (use exactly these hex values):
- Primary background: deep navy blue gradient from #0A1965 to #102F8B.
- Accent / highlight color: teal #01989C and cyan #0FD1C4.
- Card surfaces: white #FFFFFF.
- Secondary surface: light gray #F0F3F9.
- Title text: white. Subtitle text: teal #0FD1C4.

Layout: a horizontal BPM-style flow of 3 connected rounded rectangle cards, left to right, connected by thin teal arrows, on the navy gradient background. Each card has a simple line icon at the top and a label + short sublabel below:
- Card 1 – icon: pulse/heartbeat monitor – label "Production Monitor"
  – sublabel "Real-time health of every host".
- Card 2 – icon: magnifying glass over a warning triangle – label "AI Incident Investigator" – sublabel "Evidence-based root-cause analysis".
- Card 3 – icon: chat bubble with a document – label "RAG Assistant"
  – sublabel "Cited answers from the project's own docs".

Above the flow: bold white title "IRIS Production Guardian", with a smaller teal subtitle underneath: "Built entirely on InterSystems IRIS". Keep all text minimal and legible at video-thumbnail distance. Export as a single flat image, no borders.
```

2. Production saudável, mensagens atravessando os hosts em tempo real (1-2 min)

1. Abrir `http://localhost:53773/csp/guardian/Guardian.UI.MonitorPage.cls` (login `guardian` / `guardian` se pedir; esta é a única URL de página da aplicação que você digita na gravação inteira — as próximas trocas de tela são sempre pelo menu lateral). Mostrar `State: Running` e os hosts com badge `healthy` .
2. Na segunda janela de terminal, iniciar o loop de tráfego contínuo — manda uma mensagem `LOW` a cada 6 segundos, para o Monitor parecer uma produção viva (contadores de fila/mensagens se movendo o tempo todo) em vez de um disparo único e estático. **Isto é um script inteiro — cole o bloco todo de uma vez, não linha por linha:**

```
I=0
DIR=/durable/guardian/in
while true; do
  I=$((I + 1))
  ID="LOOP-$(date +%H%M%S)-${I}"
  FILE="$DIR/loop_${I}.txt"
  MSG="${ID}|IRIS.Service.OrderIngest|LOW|Trafego continuo de demonstracao #${I}"
  docker exec -i iris-guardian sh -c "echo '$MSG' > $FILE && chown irisowner:irisowner $FILE"
  echo "[$(date +%T)] enviado ${ID}"
  sleep 6
done
```

(Isto é o conteúdo de `docs/experiments/loop_trafego_saudavel.sh` — pode rodar `sh docs/experiments/loop_trafego_saudavel.sh` em vez de colar o bloco acima, dá no mesmo, e evita qualquer risco de colagem quebrada. Aceita um número como argumento para trocar o intervalo, ex. `sh docs/experiments/loop_trafego_saudavel.sh 10`.)

Deixar rodando em primeiro plano nessa janela **durante toda a gravação** (seções 2 a 7) — só interromper com Ctrl+C na seção de limpeza, no final. Cada mensagem é severidade `LOW`, roteada para `/durable/guardian/out` (via `Guardian.Operation.FileOutputOperation`); não interfere na falha controlada da seção 3, que afeta só `/durable/guardian/out_priority` (destino exclusivo de `CRITICAL / HIGH / MEDIUM`, decidido por `Guardian.Rule.IncidentRoutingRule` — bônus de Business Rules, ver seção 7).

3. Voltar para o Monitor na tela e apontar o horário de coleta e os contadores de fila/mensagens mudando a cada ~6s, conforme o loop envia. Opcional, para reforçar que é tráfego real chegando por arquivo, não simulado na interface (comando único):

```
docker exec -i iris-guardian ls -la /durable/guardian/out
```

Fala sugerida: “aqui está o estado saudável, com tráfego real entrando continuamente — vou guardar essa imagem para comparar depois da falha.”

3. Introduzir a falha controlada (2-3 min)

1. Quebrar o destino ao vivo, na tela (comando único):

```
docker exec -i iris-guardian chmod 555 /durable/guardian/out_priority
```

Isso remove a permissão de escrita do usuário `irisowner` (dono do processo IRIS) no diretório de saída usado por incidentes `CRITICAL / HIGH / MEDIUM` — simula um destino indisponível de verdade (disco cheio, permissão negada, share fora do ar), sem tocar em nada dentro do IRIS.

Fala sugerida: “estou removendo a permissão de escrita do diretório de saída usado por incidentes críticos — simula um destino indisponível de verdade, não uma falha fingida na interface.”

2. Disparar o incidente que vai falhar (comando único):

```
docker exec -i iris-guardian sh -c 'F=/durable/guardian/in/demo3.txt; echo "INC-003|IRIS.Service.PaymentGateway|CRITICAL|Falha de escrita simulada no destino" > $F && chown irisowner:irisowner $F'
```

3. Voltar para o Monitor na tela (menu lateral esquerdo → **Monitor**) e **esperar ao vivo** (~15-20s — o `FailureTimeout` padrão do `Ens.BusinessOperation` é real, não cortar esse tempo no vídeo).

Fala sugerida (comparação com a tela anterior — item 6.4, sem pressupor que quem assiste conhece interoperability):

"Repare na lista de hosts do Monitor: cada linha é um componente que processa mensagens dentro da produção. Duas delas — o `FileIncidentService`, que recebe os arquivos de incidente, e o `FileOutputOperation`, que escreve as saídas normais — continuam verdes, ou seja, saudáveis, processando normalmente, porque o tráfego contínuo do loop que deixei rodando não usa o destino que acabei de bloquear.

As outras duas mudaram de cor, de verde para amarelo: o `IncidentRouterProcess`, que é o componente que decide para onde cada incidente deve ir, e principalmente o `PriorityOutputOperation`, que é exatamente o componente que tentou escrever no diretório que eu bloqueei no passo anterior. Amarelo aqui significa `degraded` — degradado, não fora do ar.

O que isso mostra na prática é que a falha é isolada: ela não derrubou a aplicação inteira, só o caminho específico que estava tentando escrever no destino problemático. O tráfego normal, que passa pelo caminho verde, nem percebeu que algo deu errado — e isso vai ficar ainda mais claro no próximo passo, olhando os contadores."

Nesse meio-tempo o loop de tráfego (seção 2) continua rodando na outra janela — apontar que os contadores de `Guardian.Operation.FileOutputOperation` (caminho normal, severidade LOW) continuam subindo normalmente enquanto só o operation de saída prioritária degrada.

4. Confirmar o erro real via SQL ao vivo (guardar o `ID` da última linha com `TargetConfigName = Guardian.Operation.FileOutputOperation` e `ErrorStatus` diferente de `1` — vai precisar dele na seção 6 se for demonstrar o reenvio manual por comando). **Heredoc — cole as 6 linhas de uma vez:**

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'

set st=##class(%SQL.Statement).%New()
set sc=st.%Prepare("SELECT ID,TargetConfigName,Status,ErrorStatus FROM Ens.MessageHeader ORDER BY ID DESC")
set rs=st.%Execute()
do rs.%Display()
halt
EOF
```

Deve aparecer `ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'`, embrulhado em `<Ens>ErrFailureTimeout`. Alternativa visual (mais direta para gravar): no Management Portal, clicar em **Interoperability** (menu esquerdo) → **View** → **Messages** e mostrar a mensagem com erro na lista.

Fala sugerida: “aqui a falha é real, não simulada na interface — o processo tentou escrever e o sistema operacional recusou.”

4. Abrir o incidente no AI Incident Investigator (2-3 min)

1. Clicar em **Investigator** no menu lateral esquerdo da aplicação.
2. Selecionar o componente `Guardian.Operation.PriorityOutputOperation` e uma janela de tempo que cubra o momento da falha (ex. 60 minutos).
3. Clicar em “Investigate”. A tela escurece com um overlay (logo Production Guardian + spinner animado) até a análise da IA terminar — comportamento normal, não é travamento; o overlay fica visível durante todo o processamento real, inclusive se a chamada à IA demorar vários segundos. Bom momento para narrar “a IA está analisando agora, em tempo real”.
4. Rodar a análise e **ler na tela, para a câmera**, a separação entre observação (o que os dados mostram), hipótese (o que provavelmente causou) e lacunas (o que não dá para afirmar com os dados disponíveis) — esse é o ponto central do DoD: “fundamenta hipóteses em evidências e não executa remediação automática”. Não clicar em nada que sugira “corrigir automaticamente” — não existe esse botão, e a fala deve deixar claro que a decisão de corrigir é humana.

5. Perguntar aos dois RAG Assistants (3-4 min)

Perguntas já calibradas contra o corpus real do projeto (10 perguntas testadas, limiar de abstenção 0.58; as relevantes ficaram entre 0.668-0.761 de similaridade, as irrelevantes entre 0.507-0.521 — gap limpo, sem ambiguidade). Usar exatamente as perguntas abaixo para garantir que a gravação dá certo na primeira tentativa. Assim como no Investigator (seção 4), clicar em “Ask”/“Perguntar” escurece a tela com o mesmo overlay

de carregamento até a resposta chegar — normal, não cortar.

1. Clicar em **RAG Assistant (Gemini)** no menu lateral esquerdo. Perguntar: > “Qual a causa do erro #5005?”

Esperado: resposta com citação real de fonte (documento do corpus, similaridade ~0.67), ligando ao erro que acabou de ser gerado ao vivo na seção 3. Abrir a fonte citada na tela para mostrar que não é invenção.
2. Ainda no RAG (Gemini), perguntar uma pergunta **sem suporte no corpus**, para demonstrar abstenção: > “Qual a receita de bolo de chocolate?”

Esperado: o modelo responde que não sabe / não há informação (similaridade real ~0.52, abaixo do limiar 0.58) — **não deve inventar uma resposta**. Momento de narrar: “aqui o sistema se recusa a responder porque não há nada no corpus sobre isso — isso é a abstenção calibrada, não um bug.”
3. Clicar em **RAG Assistant (Groq)** no menu lateral esquerdo e repetir a pergunta 1 (“Qual a causa do erro #5005?”). Mostrar que o segundo provedor também responde com citação — reforça que retrieval/embeddings são os mesmos (Gemini) e só o modelo de geração muda (Groq, `openai/gpt-oss-120b`).

Se alguma dessas perguntas não repetir o resultado esperado no dia da gravação (ex.: corpus mudou), **não inventar** — gravar o resultado real e ajustar a fala, nunca a tela.

6. Corrigir o destino e mostrar recuperação (2 min)

1. Corrigir a permissão (comando único):

```
docker exec -i iris-guardian chmod 755 /durable/guardian/out_priority
```

2. Mostrar recuperação automática para tráfego novo (comando único):

```
docker exec -i iris-guardian sh -c 'F=/durable/guardian/in/demo4.txt; echo "INC-004|IRIS.Service.PaymentGateway|LOW|Fluxo normal apos recuperacao do destino" > $F && chown irisowner:irisowner $F'
```

- Aguardar ~10s, mostrar `incident_INC-004.txt` aparecendo em `out/` e o Monitor voltando para `healthy`.
3. Explicar que a mensagem `INC-003` que falhou **não** é reentregue sozinha — o `FailureTimeout` já expirou antes do destino ser corrigido, então aquela tentativa específica ficou definitivamente marcada como falha (comportamento real e documentado do framework, não uma limitação do código). Duas formas de mostrar o reenvio manual, se quiser demonstrar ao vivo (opcional):
 - **Pelo Message Viewer** (mais direto para gravar): no Management Portal, clicar em **Interoperability** (menu esquerdo) → **View** → **Messages** → selecionar a mensagem do `INC-003` com erro → botão **Resend**.
 - **Por comando**, usando o `ID` anotado na seção 3, passo 4 (heredoc — cole as 4 linhas de uma vez):

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
set sc=##class(Ens.MessageHeader).ResendMessage(<ID_DA_MENSAGEM>)
write "Resend sc: ",sc,!
halt
EOF
```

Confirmar `incident_INC-003.txt` aparecendo em `out_priority/` depois do reenvio.

Fala sugerida: “o sistema se recupera sozinho para tráfego novo, sem reiniciar nada — e nada foi escondido ou fingido como sucesso enquanto a mensagem antiga continuava marcada como falha.”

7. Bônus implementados (2-3 min)

7.1 Business Rules routing

O caminho abaixo foi testado ao vivo nesta revisão: o link direto `EnsPortal.RuleEditor.zen?RULE=Guardian.Rule.IncidentRoutingRule.cls` não carrega o diagrama da regra sozinho — ele só define o nome que aparece na barra de navegação, mas a área de edição fica vazia até você clicar em “Open” e escolher a regra manualmente. Por isso, siga os cliques abaixo em vez de confiar só na URL:

1. No Management Portal, clicar em **Interoperability** no menu lateral esquerdo.
2. Clicar em **Build**.
3. Clicar em **Business Rules**.

Management Portal

[Home](#)
[About](#)
[Help](#)
[Contact](#)
[Logout](#)

Menu

Server c57ef8318d8f
Namespace [GUARDIAN](#)
User [guardian](#)
Licensed To InterSystems IRIS Community
Instance IRIS

Welcome, guardian
View:

Search

Home

Analytics

Interoperability

System Operation

System Explorer

System Administration

Configure

Build

View

List

Monitor

Manage

Interoperate

Test

Business Processes

Data Transformations

Business Rules

Record Maps

CSV Record Wizard

Complex Record Maps

SYSTEM INFORMATION
General details on this system
[View System Dashboard](#)

System Up Time
0d 0h 28m

PRODUCTIONS
Productions running on this system

Guardian.Production.Guardian in GUARDIAN
Stopped
[View details](#)

Caminho de cliques: Interoperability (1) → Build (2) → Business Rules (3)

4. Isso abre o Rule Editor vazio. Clicar no botão **Open** no canto superior direito.

5. No diálogo que abre, clicar duas vezes em **Business Rules** (ícone de pacote verde) → depois em **Rule** → depois em **IncidentRoutingRule** — ou selecionar o nome e clicar **OK**.

6. A regra carrega assim:



Management Portal

HomeAboutHelpLogout

Menu

Server c57ef8318d8fNamespace **GUARDIAN**User guardianLicensed To InterSystems IRIS CommunityInstance IRIS

Interoperability > Rule Editor - (Guardian.Rule.IncidentRoutingRule)

Rule Editor

NewOpenSaveSave AsContractExpand

☐ Open new windows100% ▾

generalruleSet: (#1)test

↑↓+×↺↻fx

ruleSet

name

effectiveBegin

effectiveEnd

1 rule

name RouteBySeverity

disabled false

1 when

condition

Severity="HIGH"ORSeverity="CRITICAL"Severity="MEDIUM"

return

value "Guardian.Operation.PriorityOutputOperation"

otherwise

return

value "Guardian.Operation.FileOutputOperation"

»



Rule Assistant

Select an item within the rules diagram to see a description and options.

☒ Turn off the viewing of property name in the diagram.

Regra RouteBySeverity carregada, mostrando a condição de severidade e os dois destinos possíveis

Fala sugerida:

“Este é o Business Rules Editor do IRIS — um editor visual de regras de negócio. A regra que estou mostrando, `RouteBySeverity`, é a que decide para onde cada incidente vai: se a severidade for `HIGH`, `CRITICAL` ou `MEDIUM`, a regra devolve o nome do `Guardian.Operation.PriorityOutputOperation` — o destino prioritário que acabei de testar na falha controlada. Para qualquer outra severidade, ela devolve o `Guardian.Operation.FileOutputOperation`, o destino normal. O ponto importante aqui é que essa decisão de roteamento é configurável visualmente, sem recompilar nada — se eu quisesse

adicionar uma quarta severidade ou trocar o destino, eu editaria essa regra aqui e recompilaria só ela, sem tocar no código dos outros componentes. É exatamente essa regra que decidi, nas seções 3 e 6, mandar o `INC-003` e o `INC-004` para destinos diferentes.”

7.2 Hybrid search

Não precisa clicar em nada além do que já foi feito na seção 5 — é uma decisão de arquitetura que já rodou por trás de toda pergunta feita ao RAG Assistant. Só narrar:

Fala sugerida (detalhada, item 6.6):

"A busca do RAG Assistant não usa só uma técnica, ela combina duas. A primeira é busca vetorial: a pergunta do usuário é transformada num vetor numérico, um embedding, e comparada por similaridade com o vetor de cada trecho da documentação — isso captura o significado da pergunta, mesmo que as palavras exatas sejam diferentes das do documento. A segunda é busca lexical, usando o índice de texto completo nativo do IRIS, o iFind — isso captura correspondências exatas de palavras-chave, que a busca por significado às vezes não prioriza.

Os dois rankings são combinados por um método chamado Reciprocal Rank Fusion: cada busca contribui com até 15 candidatos, e a posição de cada trecho nos dois rankings é combinada matematicamente para montar os 5 trechos finais que a IA usa para responder.

Na prática, isso significa: se a pergunta usa um termo técnico exato que aparece literalmente na documentação, a busca lexical ajuda a garantir que esse trecho apareça; se a pergunta é feita com outras palavras, a busca vetorial ainda encontra o trecho certo pelo significado. A decisão de abstenção, aliás, continua baseada só na melhor similaridade vetorial pura — não muda por causa da fusão híbrida, para não invalidar a calibração que testei."

7.3 PublicHealth bonus

Mencionar que existe uma segunda Production (`PublicHealthProduction`), que consome uma API pública real (`disease.sh`) e trata indisponibilidade sem inventar dados. Se quiser mostrar ao vivo (só uma Production roda por namespace, então precisa parar a atual primeiro — decidir se vale o tempo de vídeo ou só citar com print/trecho de código):

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
do ##class(Ens.Director).StopProduction()
set sc=##class(Ens.Director).StartProduction("Guardian.Production.PublicHealthProduction")
write "Start PublicHealth sc: ",sc,!
halt
EOF
```

Para voltar à Production principal depois (necessário para o resto do roteiro, se gravar isso fora de ordem):

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
do ##class(Ens.Director).StopProduction()
set sc=##class(Ens.Director).RecoverProduction()
set sc=##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction")
write "Start Guardian sc: ",sc,!
halt
EOF
```

8. Metodologia com IA (1 min)

Mostrar a pasta `entregaveis/Prompts/` no Finder ou editor de código — 10 arquivos com a sequência real de prompts por fase/bônus, com os erros reais encontrados e corrigidos. Não precisa ler o conteúdo na tela, só apontar que existe e abrir um arquivo rapidamente como exemplo.

9. Encerramento (30-45s)

Fala sugerida (item 6.7, exata, com tudo o que você precisa citar):

“Esse foi o IRIS Production Guardian: um Production Monitor em tempo real, um AI Incident Investigator que fundamenta hipóteses em evidência sem executar nada sozinho, e um RAG Assistant que cita a fonte e sabe dizer que não sabe. Além do escopo obrigatório, entreguei quatro bônus: roteamento por Business Rules, busca híbrida vetorial e lexical, um segundo provedor de IA para geração de resposta, e uma segunda produção que integra uma API pública de saúde. Todo o código está aberto no repositório GitHub — o link está na descrição deste vídeo. Obrigado por assistir.”

Links a citar/mostrar (para você não precisar lembrar de nada fora deste documento):

- Repositório GitHub (já existe, pode citar/mostrar na tela): `https://github.com/sergiofsq/iris-production-guardian`
- Link do vídeo publicado e link no Open Exchange: **ainda não existem no momento da gravação** — só serão criados depois que o vídeo for publicado, então não têm como ser citados na fala. Ficam para preencher depois em `entregaveis/Artigo_Comunidade_PT.md` (ver checklist final).

Limpeza pós-gravação

1. Parar o loop de tráfego (seção 2) — Ctrl+C na janela onde ele está rodando, ou, se foi deixado em segundo plano: `pkill -f loop-trafego-saudavel` (ou `pkill -f "durable/guardian/in"` se rodou o bloco colado em vez do script).
2. Limpar os diretórios (comando único):

```
docker exec -i iris-guardian sh -c 'D=/durable/guardian; rm -f $D/in/* $D/archive/* $D/out/* $D/out_priority/*'
```

3. Deixar a Production `Running` (estado padrão entre sessões) — se tiver testado o bônus PublicHealth (seção 7), confirmar que voltou para `Guardian.Production.GuardianProduction`, não `PublicHealthProduction`.

Checklist final antes de publicar o vídeo

- ☐ Nenhuma chave de API, senha ou dado pessoal visível em nenhum frame (revisar principalmente aberturas de terminal e barra de favoritos do navegador).
- ☐ Interface e texto em inglês na tela (requisito do concurso) — o toggle EN no canto superior da sidebar reflete corretamente em todas as 4 páginas (auditado em 17/09/2026).
- ☐ Nenhum corte esconde uma espera real ou sugere um tempo falso de recuperação.
- ☐ Preencher, depois de publicado, o link do vídeo em `entregaveis/Artigo_Comunidade_PT.md`.