

Roteiro de Gravação V8

Passo a passo com prints reais, feito para quem nunca trabalhou com interoperabilidade

Versão de 19/09/2026 · Todos os 25 prints + R1/R2 são reais · Login da aplicação e do Management Portal: guardian / guardian

Estado deste arquivo (leia primeiro): versão definitiva — **todos os 25 prints (mais R1/R2) são reais**, sem nenhum quadro "PRINT PENDENTE" restante. 23 foram capturados ao vivo pelo Claude contra a aplicação e o Management Portal rodando de verdade (Playwright, sem precisar de tela física); **P01** (mesa de gravação) e **P25** (pasta `entregaveis/Prompts` no Finder) foram capturados manualmente pelo dono do projeto, já que são a tela física do Mac. Esta revisão corrigiu 9 pontos que só apareceram testando ao vivo (a) a (d) herdados das versões anteriores, (e) a (i) novos — ver abaixo: (a) o print do erro #5005 exige dois cliques a mais do que o documentado antes — abrir a aba **Trace** da mensagem, clicar em **View Full Trace** e depois no losango vermelho de erro; (b) o diálogo "Open" do Rule Editor tem 3 níveis reais — **Guardian** → **Rule** → **IncidentRoutingRule** — e não "Business Rules → Rule → IncidentRoutingRule" como versões anteriores descreviam; (c) **[V6]** um bug de unidade real foi corrigido no código: a janela de "erro recente" que decide o status `degraded`

(`Guardian.Monitor.StatusCollector::ErrorWindowSeconds`) estava em 900s (15 minutos) — o comentário original dizia que devia bater com o `FailureTimeout` real do framework, que é **15 segundos**, não 15 minutos. Corrigido para `15` e confirmado ao vivo: a janela de erro recente ficou em 15 segundos (a volta a `healthy` foi depois refinada no item (f)); (d) **[V7]** a mensagem de recuperação da seção 6.2 estava com severidade `LOW`, que a regra `RouteBySeverity` nunca manda para `out_priority` (o destino que quebramos e consertamos) — ela ia para `out`, que nunca esteve bloqueado, então não provava nada sobre a correção. Corrigido para `CRITICAL` (mesma severidade do `INC-003`) e confirmado ao vivo: agora o arquivo aparece de verdade em `out_priority` depois do `chmod 755`; (e) **[novo nesta versão]** `chmod 555` na pasta **não bloqueia** a regravação de um arquivo que **já existe** dentro dela (a permissão da pasta só impede criar, apagar e renomear entradas; sobrescrever um arquivo existente depende só da permissão do próprio arquivo). Como o destino grava sempre em `incident_<ID>.txt`, um `incident_INC-003.txt` deixado por uma gravação anterior fazia a demo **não** degradar. O passo 3.1 agora apaga esse arquivo antes de bloquear a pasta; e o comando de limpeza (0.4 e L.2) agora faz `chmod 755` **antes** do `rm` — com a pasta em 555 o `rm` falhava e o `chmod` encadeado por `&&` nunca rodava; (f) **[novo nesta versão]** regra do Monitor alterada: `degraded` agora também vale para **erro não recuperado** — o host continua degradado enquanto o último erro dele não for seguido de uma mensagem concluída com sucesso no mesmo caminho. Antes o estado voltava a `healthy` sozinho depois de 15 segundos mesmo com o destino ainda quebrado. Consequência para a gravação: depois do `chmod 755` os hosts só voltam a `healthy` quando a mensagem do passo 6.2 chegar com sucesso — não é mais preciso esperar 15 segundos; (g) **[novo nesta versão]** o Investigator agora tem **fallback automático para o Groq**: se o Gemini devolver erro (por exemplo HTTP 503 por alta demanda), a análise é gerada pelo Groq com o mesmo prompt, sem o usuário precisar tentar de novo; (h) **[novo nesta versão]** **tudo o que aparece na tela está em inglês**: os prints P02–P08, P12, P15–P21 foram recapturados ao vivo com a interface em EN; o corpus do RAG Assistant foi traduzido para inglês (`docs/corpus_en/`, reindexado no lugar, mantendo os IDs dos documentos), então as fontes citadas nos prints P17–P20 aparecem em inglês; as

perguntas dos passos 5.1–5.3 agora são em inglês (*What is the cause of error #5005? / What is the recipe for chocolate cake?*); a saída do script do loop e as mensagens de incidente dos passos 3.2 e 6.2 também foram para inglês, e o script foi renomeado para `healthy_traffic_loop.sh`; (i) **[pendente, é com você] P01** (mesa de gravação) precisa ser recapturado com o Management Portal em inglês, e **P25** (Finder) precisa ser recapturado depois do rename dos arquivos de `entregaveis/Prompts/` para inglês — os dois são prints da tela física do Mac e os arquivos atuais ainda mostram o idioma antigo.

Como ler este documento

Cada passo tem sempre a mesma estrutura, para você não precisar pensar:

TERMINAL	Você digita ou cola algo no Terminal do seu Mac. Todos os comandos aqui rodam no Mac , não dentro do container.
GUARDIAN	Você clica na aplicação Production Guardian, no navegador. Depois do primeiro login, navegue sempre pelo menu lateral esquerdo , nunca digitando endereço.
PORTAL IRIS	Você clica no Management Portal, o painel de administração do IRIS, em outra aba do navegador.
Em palavras simples	Uma explicação sem jargão do que está acontecendo, para você entender e conseguir falar com segurança.
O que eu digo	A fala pronta, em primeira pessoa. Pode ler igual ou adaptar mantendo o conteúdo.
Print	Imagem real da tela onde você vai clicar. A bolinha vermelha numerada marca cada clique, na ordem.

Regra dos comandos: todo bloco cinza-escuro marcado como *"Comando único"* é **uma única linha**. Copie a linha inteira (mesmo que o seu terminal mostre ela quebrada em duas) e cole de uma vez. Nunca digite `\` no fim de uma linha. Os blocos marcados como *"Bloco colado de uma vez"* têm várias linhas de propósito: cole todas juntas; o terminal só executa depois de ver a palavra `EOF` final.


Glossário para quem não conhece interoperabilidade

Leia uma vez. Depois disso, nenhuma palavra do roteiro deve ser mistério.

Termo	O que significa, em palavras simples
Interoperabilidade	Fazer sistemas diferentes conversarem entre si. Um sistema entrega um pedido, outro cobra, outro emite a nota. Alguém precisa levar a informação de um ao outro sem perder nada.
Production	A "linha de montagem" inteira. É o conjunto de peças que recebe, processa e entrega mensagens. O nome da nossa é <code>Guardian.Production.GuardianProduction</code> . Ela pode estar Running (rodando) ou parada.
Mensagem	Um pacote de informação que anda pela linha de montagem. No nosso vídeo, cada mensagem é um arquivo de texto pequeno que descreve um incidente, por exemplo "INC-003, pagamento, crítico".
Host	Uma peça da linha de montagem. Cada host faz uma tarefa. Nossa Production tem quatro (veja o quadro abaixo).
Service (entrada)	O host que <i>recebe</i> as mensagens. É a porta de entrada: fica olhando uma pasta e pega cada arquivo novo. Aqui: <code>FileIncidentService</code> .

Process (processamento)	O host que <i>decide</i> para onde a mensagem vai. Aqui: <code>IncidentRouterProcess</code> , que lê a gravidade do incidente e escolhe o destino.
Operation (saída)	O host que <i>entrega</i> a mensagem no destino final, gravando um arquivo numa pasta. Temos dois: <code>FileOutputOperation</code> (incidentes comuns) e <code>PriorityOutputOperation</code> (incidentes graves).
Fila	Mensagens esperando a vez de um host. Fila zerada é sinal de que tudo está fluindo.
Severidade	A gravidade do incidente: <code>LOW</code> (baixa), <code>MEDIUM</code> (média), <code>HIGH</code> (alta), <code>CRITICAL</code> (crítica).
Healthy / Degraded / Unavailable	Saudável (verde), degradado (amarelo: funciona com problema) e indisponível (vermelho: fora do ar). Um host fica <code>degraded</code> enquanto houver fila pendente, um erro nos últimos 15 segundos (a mesma janela que o framework usa para desistir de uma tentativa, o <code>FailureTimeout</code>) ou um erro ainda não recuperado : o último erro dele não foi seguido de uma mensagem concluída com sucesso no mesmo caminho. Ele volta a <code>healthy</code> quando uma mensagem nova passa com sucesso.
Management Portal	O painel de administração do IRIS. Aqui você enxerga a Production "por dentro", inclusive cada mensagem que passou por ela.
Message Viewer	A tela do Management Portal que lista todas as mensagens, com horário, origem, destino e se deu erro. É a "prova real" do tráfego.
Business Rule	Uma regra de negócio configurada visualmente, sem programar. A nossa decide: gravidade alta, crítica ou média vai para o destino prioritário; o resto vai para o destino normal.
IA / RAG	RAG é uma IA que responde consultando a documentação do próprio projeto e citando a fonte. Se não achar nada relevante, ela diz que não sabe em vez de inventar.

Como a nossa linha de montagem funciona (o que vai aparecer no Monitor)



Na falha controlada, vamos bloquear a pasta `out_priority` . Só o caminho de baixo (prioritário) vai reclamar. O caminho normal continua verde.

Monte sua mesa de gravação antes de começar

Quatro janelas abertas, cada uma com um papel fixo.

Janela	Para que serve	Fica aberta
Terminal 1 (Mac)	Comandos pontuais: iniciar, quebrar e consertar o destino, disparar incidentes.	O vídeo inteiro
Terminal 2 (Mac, ao lado)	Só o loop de tráfego contínuo (seção 2). Fica rodando para o Monitor parecer uma produção viva.	Da seção 2 até a limpeza

0. Antes de gravar

Faça esta lista uma vez, na ordem. Nada aqui vai para o vídeo.

0.1 Esconder tudo que é pessoal

GUARDIAN No navegador, feche todas as abas que não sejam do vídeo e **oculte a barra de favoritos** (no Chrome: Cmd+Shift+B). Prints antigos deste projeto já vazaram a barra de favoritos sem querer. Se preferir, use uma janela anônima.

Nunca abra a tela de credenciais (Interoperability → Configure → Credentials). É lá que ficam as chaves de API do Gemini e do Groq. Se você não abrir essa tela, está seguro.

0.2 Ligar o container do IRIS

TERMINAL No Terminal 1:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker start iris-guardian
```

Em palavras simples: O container é um "computador dentro do computador" onde o IRIS roda. Este comando liga ele.

0.3 Conferir se a Production está rodando

TERMINAL No Terminal 1, cole as 5 linhas de uma vez, do `docker exec` até o `EOF`:

BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
write ##class(Ens.Director).GetProductionStatus(.tName,.tState),!
write "Name: ",tName," State: ",tState,!
halt
EOF
```

Em palavras simples: Você deve ver `state: 1`. O número 1 significa Running (rodando).

TERMINAL Se o estado **não** for 1, cole este bloco e confira de novo. Não passe o nome da Production para `RecoverProduction()`; isso dá erro `<PARAMETER>`:

BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
set sc=##class(Ens.Director).RecoverProduction()
write "Recover sc: ",sc,!
set sc=##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction")
write "Start sc: ",sc,!
halt
EOF
```

```
$ docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
write ##class(Ens.Director).GetProductionStatus(.tName,.tState),!
write "Name: ",tName," State: ",tState,!
halt
EOF

Name: Guardian.Production.GuardianProduction State: 1
```

PRINT P02 — Terminal 1 mostrando o resultado do comando: State: 1.

0.4 Limpar as pastas de mensagens

TERMINAL No Terminal 1:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian sh -c 'D=/durable/guardian; chmod 755 $D/out $D/out_priority && rm -f $D/i
n/* $D/archive/* $D/out/* $D/out_priority/*'
```

Em palavras simples: Apaga os arquivos de testes anteriores para o vídeo começar do zero e garante que as pastas de saída aceitam gravação. O `chmod` vem **antes** do `rm` de propósito: se a pasta `out_priority` ficou em 555 da gravação anterior, o `rm` falharia com "Permission denied".


0.5 Refresh forçado e idioma em inglês

GUARDIAN No navegador, abra

<http://localhost:53773/csp/guardian/Guardian.UI.MonitorPage.cls> (é a **única** URL de página que você digita na gravação inteira). Faça login com **guardian / guardian** e dê um refresh forçado:

Cmd+Shift+R.

GUARDIAN No **canto superior da barra lateral**, clique no botão de idioma até aparecer **EN**. O concurso exige interface em inglês na gravação. Confira que o título da aba do navegador também ficou em inglês em cada página que abrir.



PRINT P03 — Barra lateral do Guardian com o botão de idioma em EN.

0.6 Ensaio completo sem gravar

Faça o vídeo inteiro uma vez, cronometrando, sem gravar. Corrija qualquer trava antes da tomada real. Decida também se vai narrar ao vivo ou legendar depois: cada passo já tem a fala pronta.

1. Abertura (30 a 60 segundos)

Tela parada, sem clicar em nada.

1.1 Mostrar a aplicação e falar

GUARDIAN Deixe o navegador na tela do **Production Monitor**, já logado, sem navegar. Se preferir, mostre antes o slide de abertura (item 1.2).

Em palavras simples: Você está apresentando três ferramentas dentro de um mesmo produto: uma que *mostra* a saúde da linha de montagem, uma que *investiga* falhas com IA, e uma que *responde perguntas* sobre a documentação.

O QUE EU DIGO (primeira pessoa)


Este é o IRIS Production Guardian, uma aplicação que construí inteiramente sobre a plataforma InterSystems IRIS para resolver um problema real de operação: quando algo falha num ambiente de integração, alguém precisa entender o que aconteceu, rápido, e não pode simplesmente confiar numa resposta genérica.

A aplicação tem três módulos. O primeiro é o Production Monitor, que mostra em tempo real o estado de cada host da produção, se está saudável, degradado ou fora do ar, e quantas mensagens estão passando por cada um.

O segundo é o AI Incident Investigator. Quando um componente falha, eu seleciono o componente e uma janela de tempo, e a IA analisa os dados reais da falha e monta uma investigação estruturada: o que os dados mostram, qual é a hipótese mais provável da causa, e o que não dá para afirmar com certeza. Ela nunca corrige nada sozinha, a decisão de agir continua sendo minha.

O terceiro é o RAG Assistant, que responde perguntas sobre a documentação do próprio projeto citando a fonte real, e se recusa a responder quando não tem informação suficiente, em vez de inventar uma resposta. Implementei duas versões, uma com Gemini e outra com Groq, para mostrar que a arquitetura funciona com mais de um provedor de IA.

Tudo isso roda sobre o InterSystems IRIS: a produção de interoperabilidade, o armazenamento vetorial da busca híbrida, e a orquestração dos três módulos.



PRINT P04 — Guardian na tela inicial (Production Monitor), estado saudável, idioma EN.

1.2 Slide de abertura (opcional)

Se quiser um slide em vez da aplicação parada, cole o prompt abaixo numa IA geradora de imagem (Gemini, ChatGPT, Ideogram). Ele usa as cores reais da aplicação.

Design a single widescreen (16:9, 1920x1080) title slide for the opening of a product demo video called "IRIS Production Guardian", built on InterSystems IRIS. Style: clean, modern, minimal enterprise SaaS dashboard aesthetic, flat design, soft shadows, rounded rectangles, no photorealism, no stock-photo people, no watermarks.

Color palette (use exactly these hex values):

- Primary background: deep navy blue gradient from #0A1965 to #102F8B.
- Accent / highlight color: teal #01989C and cyan #0FD1C4.
- Card surfaces: white #FFFFFF.
- Secondary surface: light gray #F0F3F9.
- Title text: white. Subtitle text: teal #0FD1C4.

Layout: a horizontal BPM-style flow of 3 connected rounded rectangle cards, left to right, connected by thin teal arrows, on the navy gradient background. Each card has a simple line icon at the top and a label + short sublabel below:

- Card 1 - icon: pulse/heartbeat monitor - label "Production Monitor" - sublabel "Real-time health of every host".
- Card 2 - icon: magnifying glass over a warning triangle - label "AI Incident Investigator" - sublabel "Evidence-based root-cause analysis".
- Card 3 - icon: chat bubble with a document - label "RAG Assistant" - sublabel "Cited answers from the project's own docs".

Above the flow: bold white title "IRIS Production Guardian", with a smaller teal subtitle underneath: "Built entirely on InterSystems IRIS". Keep all text minimal and legible at video-thumbnail distance. Export as a single flat image, no borders.

2. Production saudável, com mensagens passando em tempo real (1 a 2 minutos)


Objetivo: mostrar como é o "normal", para o público perceber a diferença quando algo quebrar.

2.1 Mostrar o Monitor saudável

GUARDIAN Na aba do Guardian, clique em **Monitor** no menu lateral esquerdo.

Em palavras simples: O Monitor é um painel que se atualiza sozinho a cada 10 segundos. Cada cartão é um host. Verde com a palavra **healthy** significa: sem fila parada e sem erro recente.

Aponte com o mouse para: **State: Running**, os quatro cartões com badge **healthy** e o horário de coleta.



PRINT P05 — Production Monitor saudável: State Running, quatro hosts healthy.

2.2 Ligar o tráfego contínuo

TERMINAL Abra o **Terminal 2** (a janela ao lado). Ele vai mandar uma mensagem de baixa gravidade (**LOW**) a cada 6 segundos. Cole o bloco inteiro de uma vez; ele é um script completo.

SCRIPT INTEIRO, COLE TUDO DE UMA VEZ

```

I=0
DIR=/durable/guardian/in
while true; do
  I=$((I + 1))
  ID="LOOP-$(date +%H%M%S)-${I}"
  FILE="$DIR/loop_${I}.txt"
  MSG="${ID}|IRIS.Service.OrderIngest|LOW|Continuous demo traffic #${I}"
  docker exec -i iris-guardian sh -c "echo '$MSG' > $FILE && chown irisowner:irisowner $FILE"
  echo "[$(date +%T)] sent ${ID}"
  sleep 6
done

```

Alternativa mais segura (mesmo resultado, sem risco de colagem quebrada), no Terminal 2, dentro da pasta do projeto:

COMANDO ÚNICO

```
sh docs/experiments/healthy_traffic_loop.sh
```

Para mudar o intervalo para 10 segundos: `sh docs/experiments/healthy_traffic_loop.sh 10`.

Em palavras simples: Cada arquivo criado na pasta `in` é uma mensagem entrando na linha de montagem. Você vai ver no Terminal 2 uma linha nova a cada 6 segundos dizendo "sent LOOP-...". Deixe rodando **até a limpeza, no final**; só pare com Ctrl+C lá.

```

$ sh docs/experiments/healthy_traffic_loop.sh
Sending one LOW message every 6s to /durable/guardian/in (Ctrl+C to stop)...
[20:32:20] sent LOOP-203220-1
[20:32:26] sent LOOP-203226-2
[20:32:32] sent LOOP-203232-3

```

PRINT P06 — Terminal 2 com o loop rodando, linhas "sent LOOP-..."

2.3 Mostrar que o tráfego é real

GUARDIAN Volte ao **Monitor** e aponte o horário de coleta e os contadores de **Mensagens** subindo a cada poucos segundos.

Opcional, para provar que são arquivos de verdade chegando e não algo simulado na tela:

TERMINAL No Terminal 1:

COMANDO ÚNICO

```
docker exec -i iris-guardian ls -la /durable/guardian/out
```

O QUE EU DIGO (primeira pessoa)

Aqui está o estado saudável, com tráfego real entrando continuamente. Vou guardar essa imagem para comparar depois da falha.

PT

PRODUCTION GUARDIAN

MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction Running - 2026-09-20 23:28:40

Guardian.Service.FileInciden...

Guardian.Process.IncidentR...

Guardian.Operation.FileOutp...

Guardian.Operation.Priority...

View full details →

Production Monitor

Production: Guardian.Production.GuardianProduction · State: Running · Collected at: 2026-09-20 23:28:40 (refreshes every 10s)

INBOUND HOSTS (SERVICE)

Guardian.Service.FileIncidentService

HEALTHY

Queue: 0 · Messages: 725 · Recent errors: 0

queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

PROCESSING HOSTS (PROCESS)

Guardian.Process.IncidentRouterProcesses

HEALTHY

Queue: 0 · Messages: 2175 · Recent errors: 0

queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

OUTBOUND HOSTS (OPERATION)

Guardian.Operation.FileOutputOperation

HEALTHY

Queue: 0 · Messages: 1386 · Recent errors: 0

queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

Guardian.Operation.PriorityOutputOperation

HEALTHY

Queue: 0 · Messages: 64 · Recent errors: 0

queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

States: healthy = no pending queue and no recent error · degraded = pending queue, error in the last 15 seconds, or last error not yet followed by a successful message on the same path · unavailable = host disabled or Production stopped · unknown = no message recorded yet for this host (absence of data is not health) · stuck = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (/api/guardian/status) - no independent scheduled collector in this v1.

PRINT P07 — Monitor com contadores de mensagens aumentando (compare dois momentos).

```
$ docker exec -i iris-guardian ls -la /durable/guardian/out
total 40
drwxr-xr-x 2 irisowner irisowner 20480 Sep 20 23:32 .
drwxr-xr-x 6 irisowner irisowner 4096 Sep 10 23:13 ..
-rwxrw-r-- 1 irisowner irisowner 148 Sep 20 23:32 incident_LOOP-203220-1.txt
-rwxrw-r-- 1 irisowner irisowner 148 Sep 20 23:32 incident_LOOP-203226-2.txt
-rwxrw-r-- 1 irisowner irisowner 148 Sep 20 23:32 incident_LOOP-203232-3.txt
-rwxrw-r-- 1 irisowner irisowner 148 Sep 20 23:32 incident_LOOP-203238-4.txt
```

PRINT P08 — Terminal 1 listando a pasta out com os arquivos chegando.

2.4

Mostrar o tráfego por dentro, no painel de administração do IRIS

PORTAL IRIS


Abra uma **nova aba** e digite `http://localhost:53773/csp/sys/UtilHome.csp`. Entre com **guardian / guardian** se pedir.

PORTAL IRIS


No menu esquerdo, clique em **Interoperability** (1) → **View** (2) → **Messages** (3).

Em palavras simples:

Message Viewer é uma tabela com uma linha para cada mensagem que passou pela Production. Cada linha mostra a hora, quem enviou (**Source**), quem recebeu (**Target**) e o status. É a "nota fiscal" de tudo o que aconteceu.



PRINT P09 — Management Portal, menu Interoperability → View → Messages.



PRINT P10 — Message Viewer listando as mensagens LOOP-... com Status Completed.

O QUE EU DIGO (primeira pessoa)

Este é o painel de administração do IRIS. Aqui eu vejo cada mensagem que atravessou a produção: de onde veio, para onde foi e se terminou bem. Repare que as mensagens do meu tráfego contínuo estão todas concluídas, sem erro.

3. Introduzir a falha controlada (2 a 3 minutos)

Vamos quebrar de verdade um dos destinos e ver o sistema reagir.

3.1 Bloquear o destino prioritário

TERMINAL No Terminal 1:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian sh -c 'D=/durable/guardian/out_priority; rm -f $D/incident_INC-003.txt && chmod 555 $D'
```

Achado ao vivo: `chmod 555` na pasta **não** impede regravar um arquivo que **já existe** dentro dela. Se um `incident_INC-003.txt` de uma tentativa anterior ainda estiver lá, o IRIS simplesmente sobrescreve e o Monitor fica verde. Por isso o comando acima apaga esse arquivo **antes** de bloquear — assim o IRIS precisa *criar* o arquivo e falha de verdade.

Em palavras simples: Duas coisas em um comando só: (a) remove o `incident_INC-003.txt` de uma gravação anterior, se existir; (b) `chmod 555` tira a permissão de gravar na pasta `out_priority`. É como trancar a porta do destino. A pasta continua existindo, mas ninguém consegue escrever nela. Isso simula um disco cheio, uma permissão negada ou uma rede fora do ar. Não mexemos em nada dentro do IRIS.

O QUE EU DIGO (primeira pessoa)

Estou removendo a permissão de escrita do diretório de saída usado por incidentes críticos. Isso simula um destino indisponível de verdade, não uma falha fingida na interface.

```
$ docker exec -i iris-guardian chmod 555 /durable/guardian/out_priority
```

PRINT P11 — Terminal 1 depois do `chmod 555` (sem mensagem de erro é normal).

3.2 Disparar um incidente grave

TERMINAL No Terminal 1. Este é **um comando só**, colado inteiro, em uma linha:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian sh -c 'F=/durable/guardian/in/demo3.txt; echo "INC-003|IRIS.Service.PaymentGateway|CRITICAL|Simulated write failure at the destination" > $F && chown irisowner:irisowner $F'
```

Em palavras simples: Este comando faz três coisas encadeadas dentro de **um único** comando: (a) guarda o caminho do arquivo numa variável `$F`; (b) cria o arquivo com o incidente `INC-003` de severidade `CRITICAL`; (c) entrega a posse do arquivo ao usuário do IRIS (`chown`). Você **não** precisa rodar cada parte separada.

Como é `CRITICAL`, a regra de negócio vai mandar esta mensagem para o destino prioritário, justamente a pasta que acabamos de trancar.

3.3 Ver a falha aparecer no Monitor (espere ao vivo)

GUARDIAN Volte à aba do Guardian e clique em **Monitor** no menu lateral esquerdo. **Espere de 15 a 20 segundos, ao vivo**, sem cortar o vídeo. Esse tempo é real: é o tempo que o IRIS insiste em tentar antes de desistir (`FailureTimeout`).

O QUE EU DIGO (primeira pessoa)

Repare na lista de hosts do Monitor: cada linha é um componente que processa mensagens dentro da produção. Duas delas, o `FileIncidentService`, que recebe os arquivos de incidente, e o `FileOutputOperation`, que escreve as saídas normais, continuam verdes, ou seja, saudáveis, processando normalmente, porque o tráfego contínuo do loop que deixei rodando não usa o destino que acabei de bloquear.

As outras duas mudaram de cor, de verde para amarelo: o `IncidentRouterProcess`, que é o componente que decide para onde cada incidente deve ir, e principalmente o `PriorityOutputOperation`, que é exatamente o componente que tentou escrever no diretório que eu bloqueei no passo anterior. Amarelo aqui significa *degraded*, degradado, não fora do ar. E ele continua amarelo enquanto o problema não for resolvido: o Monitor não esquece o erro só porque o tempo passou.

O que isso mostra na prática é que a falha é isolada: ela não derrubou a aplicação inteira, só o caminho específico que estava tentando escrever no destino problemático. O tráfego normal, que passa pelo caminho verde, nem percebeu que algo deu errado, e isso vai ficar ainda mais claro no próximo passo, olhando os contadores.

Enquanto isso, o Terminal 2 segue enviando mensagens normais. Aponte que os contadores do `FileOutputOperation` continuam subindo, enquanto só a saída prioritária degrada.

Production Monitor
Production: `Guardian.Production.GuardianProduction` · State: `Running` · Collected at: `2026-09-20 23:29:09` (refreshes every 10s)

INBOUND HOSTS (SERVICE)	PROCESSING HOSTS (PROCESS)	OUTBOUND HOSTS (OPERATION)
Guardian.Service.FileIncidentService HEALTHY Queue: 0 · Messages: 730 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0	Guardian.Process.IncidentRouterProcesses DEGRADED Queue: 0 · Messages: 2190 · Recent errors: 1 queue trend (10 samples): 1, 1, 2, 2, 0, 0, 0, 0, 0, 0	Guardian.Operation.FileOutputOperation HEALTHY Queue: 0 · Messages: 1394 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0
		Guardian.Operation.PriorityOutputOperation DEGRADED Queue: 0 · Messages: 66 · Recent errors: 1 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

States: `healthy` = no pending queue and no recent error - `degraded` = pending queue, error in the last 15 seconds, or last error not yet followed by a successful message on the same path - `unavailable` = host disabled or Production stopped - `unknown` = no message recorded yet for this host (absence of data is not health) - `stuck` = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (`/api/guardian/status`) - no independent scheduled collector in this v1.

PRINT P12 — Monitor com `FileIncidentService` e `FileOutputOperation` verdes, `IncidentRouterProcess` e `PriorityOutputOperation` amarelos (*degraded*).

3.4 Provar que o erro é real: Message Viewer e o trace completo

PORTAL IRIS Volte à aba do Management Portal. Menu esquerdo: **Interoperability** → **View** → **Messages**.

Em palavras simples: A mensagem mais recente vai aparecer com **Status = Error** (é o INC-003 — o número de ID interno do IRIS é diferente do texto "INC-003" que está dentro do arquivo, isso é normal).

InterSystems[®] IRIS Data Platform Management Portal

Home About Help Logout

Menu

Server c57ef8318d8f Namespace GUARDIAN User guardian Licensed To InterSystems IRIS Community Instance IRIS

Interoperability > Message Viewer

Message Viewer Search Cancel Reset Resend Previous Next Export Open in the new UI

Sort Order: Newest First Page Size: 100 Time Format: Complete Page: 1

Basic Criteria

Status: All Type: Session Start Start Time: Start ID: End Time: End ID: Source: Target:

Extended Criteria

Saved Searches

#	ID	Time Created	Session	Status	Error	Source	Target
1	859	2026-09-19 23:42:00.929	859	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
2	856	2026-09-19 23:39:50.837	856	Error	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
3	853	2026-09-19 23:36:45.690	853	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
4	848	2026-09-19 23:36:40.681	848	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
5	847	2026-09-19 23:36:40.679	847	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
6	846	2026-09-19 12:56:44.761	846	Completed	OK	Ens.ScheduleService	Ens.ScheduleHandler
7	845	2026-09-18 14:22:24.671	845	Completed	OK	Ens.ScheduleService	Ens.ScheduleHandler
8	842	2026-09-17 18:30:24.959	842	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
9	839	2026-09-17 18:27:49.811	839	Error	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden
10	836	2026-09-17 18:27:39.800	836	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inciden

Header Body Contents Trace

Details for selected item

PRINT P13 — Message Viewer com a mensagem do INC-003 em Status Error (linha do topo).

Achado ao vivo nesta revisão: clicar na linha só abre o cabeçalho da sessão (aba **Header**), que **não** mostra o texto do erro #5005 diretamente — o **ErrorStatus** ali aparece como "OK" porque é o registro do envio original, não da tentativa que falhou. Para ver o texto real do erro, clique na mensagem, depois na aba **Trace**, depois em **View Full Trace** (abre uma janela nova) e clique no **losango vermelho** que aparece na coluna Operations — aí sim aparece o texto completo do erro.

Session ID: 856
Legend
Printable Version
Go to items 1 - 6
Items per page 40
Show events
Show internal items
Apply Filter None
Previous Page
Next Page
Previous Session
Next Session

Services
Guardian.Service
FileIncidentService

Processes
Guardian.Process
IncidentRouterProcess

Operations
Guardian.Operation
PriorityOutputOperation

2026-09-19 23:39:50.837

IncidentEvent

2026-09-19 23:39:50.839

IncidentEvent

2026-09-19 23:40:05.507

IncidentEvent

2026-09-19 23:40:05.507

IncidentEvent

2026-09-19 23:40:05.507

IncidentEvent

512

Type: Error

Text: ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'

Logged: 2026-09-19 23:40:05.903

Source: Guardian.Operation.PriorityOutputOperation

Session: 856

Job: 1528

Class: Guardian.Operation.FileOutputOperation

Method: MessageHeaderHandler

Trace: (none)

Stack From

Stack Value:

- Reported in namespace GUARDIAN
- e^MessageHeaderHandler+99^Guardian.Operation.FileOutputOperation.1^2
- e^OnTask+42^Ens.Host.1^1
- e^Start+62^Ens.Job.1^2
- e^Start+14^%SYS.Ensemble.1^1
- d^StartEnsembleJob+6^|"%SYS"|STU^1
- d^^^0

Stack When

Logged:

- \$S^MessageHeaderHandler+238^Guardian.Operation.FileOutputOperation.1 +2
- \$S^OnTask+42^Ens.Host.1 +1
- \$S^Start+62^Ens.Job.1 +2
- DO^Start+14^%SYS.Ensemble.1 +1

PRINT P14 — Detalhe do losango de erro no Trace completo, mostrando o texto do ERROR #5005.

O QUE EU DIGO (primeira pessoa)

Aqui a falha é real, não simulada na interface. O processo tentou escrever e o sistema operacional recusou.

Alternativa por comando (só se quiser mostrar em terminal; anote o ID da mensagem com erro, você vai precisar dele na seção 6). Cole as 6 linhas de uma vez:

BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
set st=##class(%SQL.Statement).%New()
set sc=st.%Prepare("SELECT ID,TargetConfigName,Status,ErrorStatus FROM Ens.MessageHeader ORDER BY ID DE
SC")
set rs=st.%Execute()
do rs.%Display()
halt
EOF
```

IRIS Production Guardian · Roteiro de Gravação V8 · 17/37

4. AI Incident Investigator (2 a 3 minutos)


A IA olha os dados reais da falha e monta uma investigação. Só lê, nunca corrige.

4.1 Abrir o Investigator e escolher o problema

GUARDIAN No menu lateral esquerdo, clique em **Investigator**.

GUARDIAN No campo **Component**, escolha `Guardian.Operation.PriorityOutputOperation`. No campo **Window (minutes)**, deixe **60**.

Em palavras simples: Você está dizendo à IA: "olhe este componente, nos últimos 60 minutos". Uma janela de 60 minutos cobre com folga o momento da falha.




PRINT P15 — Investigator com o componente PriorityOutputOperation selecionado e janela 60.

4.2 Rodar a investigação

GUARDIAN Clique em **Investigate**. A tela escurece com o logo do Production Guardian e um círculo girando. **Isso é normal, não é travamento.** Deixe o vídeo rolando durante toda a espera.

O QUE EU DIGO (primeira pessoa)

A IA está analisando agora, em tempo real, os dados reais da falha. Se o provedor principal estiver sobrecarregado, o sistema troca sozinho para o segundo provedor, sem eu precisar refazer nada.



PRINT P16 — Overlay de carregamento (logo + spinner) durante a análise.

Se o Gemini devolver um erro transitório de sobrecarga (HTTP 503), o Investigator usa o **Groq automaticamente** (fallback) e entrega a análise mesmo assim — você não precisa fazer nada. Isso realmente aconteceu na preparação desta revisão. Se os dois provedores falharem, a tela mostra a evidência coletada e uma mensagem honesta de indisponibilidade em vez de inventar uma análise.

4.3 Ler o resultado para a câmera

Leia em voz alta as partes, uma a uma. É o ponto mais importante do vídeo:

- **Summary:** resumo de uma linha do que aconteceu.
- **Observations:** o que os dados mostram.
- **Hypotheses:** a causa mais provável.
- **Gaps:** o que *não* dá para afirmar com os dados disponíveis.
- **Suggested next steps:** o que fazer a seguir — sugestão, não ação automática.

Nota sobre os eventos: a evidência lista as mensagens em que o componente escolhido é **origem ou destino**. Por isso o `IncidentRouterProcess` também aparece — ele é o outro lado de cada mensagem enviada ao `PriorityOutputOperation` (requisição) e recebida dele (resposta). Não há eventos de componentes não envolvidos.

Não clique em nada que pareça "corrigir automaticamente". Esse botão não existe, e a fala deve deixar claro que a decisão de corrigir é humana.

O QUE EU DIGO (primeira pessoa)

Repare que a IA separa o que os dados mostram, que é a observação, do que ela supõe, que é a hipótese, e do que ela não consegue afirmar, que são as lacunas. Ela também sugere os próximos passos, mas não faz nada sozinha. A decisão de agir é minha.



MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction
Running · 2026-09-20 23:29:11

Guardian.Service.FileInciden...

Guardian.Process.IncidentR...

Guardian.Operation.FileOutp...

Guardian.Operation.Priority...

[View full details →](#)

AI Incident Investigator

Real evidence (metrics, events and documentation) + AI-assisted analysis. Read-only - no automatic remediation.

Component

Guardian.Operation.PriorityOutputOperation (Operation)

 Window (minutes)

60

Investigate

CURRENT HEALTH

DEGRADED

 Queue: 0 · Messages: 66 · Recent errors: 1

EVENTS IN WINDOW (12)

msg #3026 · 2026-09-20 23:29:00.071 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'

msg #3022 · 2026-09-20 23:28:44.954 · Guardian.Process.IncidentRouterProcess →
Guardian.Operation.PriorityOutputOperation
success

msg #2890 · 2026-09-20 22:42:24.874 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success

msg #2891 · 2026-09-20 22:42:24.874 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
success

msg #2877 · 2026-09-20 22:41:52.388 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
success

msg #2875 · 2026-09-20 22:41:52.387 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success

msg #2740 · 2026-09-20 22:34:31.989 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-004.txt'

msg #2737 · 2026-09-20 22:34:16.933 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success

msg #2729 · 2026-09-20 22:33:51.906 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
success

msg #2728 · 2026-09-20 22:33:51.904 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success

msg #2714 · 2026-09-20 22:33:11.858 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
success

msg #2713 · 2026-09-20 22:33:11.857 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success

ANALYSIS

SUMMARY

Component `Guardian.Operation.PriorityOutputOperation` is currently in a `degraded` state (queue=0, messages=66, recent errors=1). Within the last 60 minutes, the component experienced intermittent failures when attempting to write incident output files to `/durable/guardian/out_priority/`, resulting in file open errors (`ERROR #5005`) and failure timeouts (`<Ens>ErrFailureTimeout`).

OBSERVATIONS

- Health Status:** Current status is `degraded`, with 0 queued messages, 66 processed messages in the window, and 1 recent error.
- Error Events:**
 - At `2026-09-20 23:29:00.071` (msg #3026): Message failed with `ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'`.
 - At `2026-09-20 22:34:31.989` (msg #2740): Message failed with `ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-004.txt'`.
- Successful Events:** Messages processed successfully right before and after failure points (e.g., msg #2713, #2714, #2728, #2729, #2737, #2875, #2877, #2890, #2891, #3022).
- Execution Behavior:** In both error instances, the operation attempted retries up to the 15-second `FailureTimeout` limit before reporting failure back to `Guardian.Process.IncidentRouterProcess`.

HYPOTHESES

- Directory Permission or Access Lock Issue:** Intermittent OS-level file access failures (`ERROR #5005`) when opening files in `/durable/guardian/out_priority/` may be caused by temporary loss of write permissions for the `irisowner` user or file-locking conflicts on the destination path.
- Storage Mount Instability:** Transient mount or disk availability issues on `/durable/guardian/out_priority/` could cause intermittent inability to write files, leading the operation to exceed its 15-second failure timeout.

GAPS

- OS-level directory permissions (`ls -la /durable/guardian/out_priority/`) at the exact times of failure are not present in the provided evidence.
- System-level disk space metrics, storage mount logs, and IRIS system logs (`messages.log`) during the 60-minute window were not provided.

SUGGESTED NEXT STEPS

- Inspect directory permissions and ownership for `/durable/guardian/out_priority/` to ensure `irisowner` maintains write access (`chmod 755`).
- Check disk space and mount point stability for the `/durable/` file system.

* Review the IRIS system event log (`messages.log`) around `22:34:31` and `23:29:00` for OS-level I/O or permission errors.

RELATED DOCUMENTATION

Phase 1 - Production COS

similarity: 0.824

```
1. Destination broken ( chmod 555 on /durable/guardian/out, removing write access from irisowner ).
2. Incident INC-003 fired. After ~15s (the framework's default FailureTimeout, confirmed in Ens.BusinessOperation||FailureTimeout = 15, RetryInterval = 5 ), the Operation records in Ens.MessageHeader.ErrorStatus :
..
<EnsErrFailureTimeout ... ERROR #5005: Cannot open file
'/durable/guardian/out/incident_INC-003.txt'
..
No output file is generated – the failure is real (an operating system error), not faked in the interface.
3. Destination fixed ( chmod 755 ).
4. A new incident ( INC-004 ) flows automatically and successfully – this confirms automatic recovery for new traffic, without restarting the Production.
5. The incident that fa
```

Phase 4 - AI Incident Investigator

similarity: 0.749

Investigation of `Guardian.Operation.FileOutputOperation` against the real history of the Phase 1 failure/recovery experiment (a window large enough to cover the 09/09/2026 data):

Phase 1 - Production COS

similarity: 0.748

```
1. Production started: ##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction") →
%Status: OK, state confirmed "running" via Ens.Director.GetProductionStatus .
2. File dropped in /durable/guardian/in/demo1.txt:
..
INC-001|IRIS.Service.OrderIngest|HIGH|Message queue above the configured limit
..
3. After the adapter's polling interval (5s), the file:
- disappeared from in/;
- appeared archived in archive/demo1.txt_2026-09-09_17.28.15.298;
- produced out/incident_INC-001.txt with the content:
..
INC-001|IRIS.Service.OrderIngest|HIGH|Message queue above the configured limit|2026-09-09
17:28:15|Guardian.Process.IncidentRouterProcess|2026-09-09 17:28:15
..
The last two fields ( ProcessedBy , ProcessedAt ) only exist b
```

Evidence Scorecard

similarity: 0.745

- Proof: `Guardian.Rule.IncidentRoutingRule` (Extends `Ens.Rule.Definition`) decides the destination config name from the `Severity` of `Guardian.Messages.IncidentEvent`; `Guardian.Process.IncidentRouterProcess` calls `##class(Ens.Rule.Definition).EvaluateRules(...)` instead of using a fixed `TargetConfigName`. A second Operation (`Guardian.Operation.PriorityOutputOperation`) was created for the second possible destination.

- Evidence: `INC-101` (HIGH) → `out_priority/`, `INC-102` (LOW) → `out/`, confirmed by file and by `Ens.MessageHeader` (Process routing dynamically to different operations in the same run). Then the rule condition was changed to include `MEDIUM` and recompiled – without touching `IncidentRouterProcess` or the Production – and `INC-103` (MEDIUM)

Phase 1 - Production COS

similarity: 0.732

- `Guardian.Rule.IncidentRoutingRule` (Extends `Ens.Rule.Definition`): XData RuleDefinition with `context="Guardian.Messages.IncidentEvent"`, a `RouteBySeverity` rule that returns the destination config name – `Guardian.Operation.PriorityOutputOperation` when `(Severity="HIGH")||((Severity="CRITICAL") , otherwise` `Guardian.Operation.FileOutputOperation` (<otherwise>).

- `Guardian.Process.IncidentRouterProcess.OnRequest` calls `##class(Ens.Rule.Definition).EvaluateRules("Guardian.Rule.IncidentRoutingRule", "", pRequest, "", .tTarget, .tReason)` and sends the message to `tTarget` (instead of the fixed `TargetConfigName`, which now only serves as the initial fallback value).

- A second Operation added to the Production (`Guardian.Operation.PriorityOutputOperation`, same c

Analysis generated by AI (Google Gemini) using only the real evidence collected above - It does not invent events or a confidence percentage, and keeps observation separate from hypothesis. Read-only investigation - no correction is applied automatically.

PRINT P17 — Resultado da investigação: Summary, Observations, Hypotheses, Gaps e Suggested next steps.

5. Perguntar aos dois RAG Assistants (3 a 4 minutos)

Use exatamente estas perguntas. Elas foram testadas contra o conteúdo real do projeto.

Em palavras simples: O RAG Assistant só responde com base na documentação do projeto e mostra de onde tirou. Se a pergunta não tem nada a ver com a documentação, ele deve dizer que não sabe. Isso se chama **abstenção**. O corte é uma similaridade de 0.58: perguntas relevantes ficam acima disso; perguntas fora do assunto, abaixo.

5.1 Gemini: pergunta com resposta na documentação

GUARDIAN Clique em **RAG Assistant (Gemini)** no menu lateral esquerdo. Digite a pergunta abaixo e clique em **Ask** (a tela escurece de novo até a resposta chegar; é normal).

What is the cause of error #5005?

Em palavras simples: Esperado: uma resposta que cita um documento real do projeto e liga ao erro que você acabou de gerar. **Clique na fonte citada** para mostrar que ela existe e não foi inventada.

RAG Assistant (Gemini)

Context: latest investigation (AI Incident Investigator)
Component: Guardian.Operation.PriorityOutputOperation · 60 min window · 2026-09-20 23:29:35

SUMMARY
Component Guardian.Operation.PriorityOutputOperation is currently in a degraded state (queue=0, messages=66, recent errors=1). Within the last 60 minutes, the component experienced intermittent failures when attempting to write incident output files to /durable/guardian/out_priority/, resulting in file open errors (ERROR #5005) and failure timeouts (<ErrFailureTimeout).

What is the cause of error #5005? **Ask**

Could not reach the AI model right now (Gemini generate HTTP 503: This model is currently experiencing high demand. Spikes in demand are usually temporary. Please try again later.). Try again shortly.

Answers generated by AI (Google Gemini) using only the documents indexed for this project - it does not invent information outside the retrieved context, and answers "I don't know" when similarity with the corpus is low. Current abstention threshold: 0.58 (initial heuristic, see docs/corpus_en/D4_PHASE_3_RAG_ASSISTANT.md).

PRINT P18 — RAG Assistant (Gemini) com a resposta e a fonte citada.

5.2 Gemini: pergunta fora do assunto (abstenção)

GUARDIAN Ainda no RAG Assistant (Gemini), pergunte:

What is the recipe for chocolate cake?

Em palavras simples: Esperado: o sistema diz que não sabe (similaridade abaixo do corte de 0.58). Ele não deve inventar uma receita.

O QUE EU DIGO (primeira pessoa)

Aqui o sistema se recusa a responder porque não há nada no conteúdo indexado sobre isso. Isso é a abstenção calibrada, não é um bug.

PT

PRODUCTION GUARDIAN

MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction Running - 2026-09-20 23:33:57

Guardian.Service.FileIncident...

Guardian.Process.IncidentR...

Guardian.Operation.FileOutp...

Guardian.Operation.Priority...

View full details →

RAG Assistant (Gemini)

Context: latest investigation (AI Incident Investigator)

Component: Guardian.Operation.PriorityOutputOperation - 60 min window - 2026-09-20 23:29:35

SUMMARY

Component Guardian.Operation.PriorityOutputOperation is currently in a degraded state (queue=0, messages=66, recent errors=1). Within the last 60 minutes, the component experienced intermittent failures when attempting to write incident output files to /durable/guardian/out_priority/, resulting in file open errors (ERROR #5005) and failure timeouts (<Ens>ErrFailureTimeout).

What is the recipe for chocolate cake?

Ask

I do not know. The provided context (the current incident investigation) does not contain a recipe for chocolate cake.

Sources used:

Evidence Scorecard

similarity: 0.489

- Proof: native full-text index %iFind.Index.Basic (idxChunkTextFind) on Guardian_RAG.Chunk.ChunkText , created in Guardian.RAG.Schema.Setup ; fused with the existing vector search via Reciprocal Rank Fusion (k=60) in Guardian.RAG.Query.Ask , a pool of up to 15 candidates from each search, final TopK 5.

- Evidence: a question with an exact error code ("What does error #5005 mean in the failure scenario?") retrieved and correctly cited the right chunk (best similarity 0.677, 5 sources); an irrelevant question ("chocolate cake recipe") still correctly abstained (similarity 0.521, below the 0.58 threshold) — confirms that the hybrid fusion did not change the abstention calibration already validated, since the gate uses only pure vector similarity.

- Finding recorded

Phase 3 - RAG Assistant

similarity: 0.476

ever on the RRF score — a deliberate decision so as not to invalidate the calibration already tested with the 2 real points (0.653 relevant / 0.518 irrelevant).

- Real tests (10/09/2026):

- "What does error #5005 mean in the failure scenario?" → retrieved and correctly cited the chunk with ERROR #5005 , 5 sources, no abstention (best similarity 0.677).

- "chocolate cake recipe" (irrelevant) → abstention kept (best similarity 0.521, below the threshold) — confirms that the hybrid fusion did not break the already-validated abstention calibration.

- "Explain GeminiClient" → retrieved 5 sources from Phase 3, all above the threshold. In that specific test Gemini also returned a real timeout error (ERROR #5922) on a first attempt — this reinforces the air

Phase 3 - RAG Assistant

similarity: 0.466

| Question | Relevant? | Best similarity |

|---|---|---|

| Why was Gemini chosen? | yes | 0.761 |

| Embedding dimension? | yes | 0.738 |

| Cause of error #5005? | yes | 0.668 |

| Why doesn't IntegratedML work? | yes | 0.686 |

| Monitor health states? | yes | 0.761 |

| Service/Process/Operation architecture? | yes | 0.673 |

| Does Foreign Table work? | yes | 0.677 |

| Capital of France? | no | 0.507 |

| Train a dog? | no | 0.515 |

| Chocolate cake? | no | 0.521 |

10/10 classified correctly by the 0.58 threshold. The relevant ones fall between 0.667-0.761, the irrelevant ones between 0.507-0.521 — a clean gap of ~0.15, with 0.58 right in the middle. The original calibration (2 points) confirmed with a set 5x larger; no adjustment needed to the threshold.

Phase 1 - Production COS

similarity: 0.463

| Class | Role | Adapter |

|---|---|---|

| Guardian.Messages.IncidentEvent | Message (Ens.Request) with the data of a synthetic incident | — |

| Guardian.Service.FileIncidentService | Business Service — reads .txt files (one incident per line, fields separated by \ |) | EnsLib.File.InboundAdapter |

| Guardian.Process.IncidentRouterProcess | Business Process (code, not BPL) — fills in ProcessedBy / ProcessedAt: and routes to the Operation | — |

| Guardian.Operation.FileOutputOperation | Business Operation — writes the processed incident as an output file | EnsLib.File.OutboundAdapter |

| Guardian.Production.GuardianProduction | Production that connects the three hosts above | — |

Phase 3 - RAG Assistant

similarity: 0.457

entials ({ SystemName = "Gemini" }) — never

in a repository file. See 01_PHASE_0_SETUP_ARCHITECTURE.md §4 for the project's secret-management pattern.

Answers generated by AI (Google Gemini) using only the documents indexed for this project - it does not invent information outside the retrieved context, and answers "I don't know" when similarity with the corpus is low. Current abstention threshold: 0.58 (initial heuristic, see docs/corpus_en/04_PHASE_3_RAG_ASSISTANT.md).

PRINT P19 — RAG Assistant recusando a pergunta sobre bolo de chocolate.

5.3 Groq: mesma pergunta 1, outro provedor de IA

GUARDIAN

Clique em **RAG Assistant (Groq)** no menu lateral esquerdo e repita: *What is the cause of error #5005?*

IRIS Production Guardian · Roteiro de Gravação V8 · 24/37

O QUE EU DIGO (primeira pessoa)

Este é o segundo provedor. A busca e os embeddings são os mesmos, do Gemini, e só o modelo que escreve a resposta muda: aqui é o openai/gpt-oss-120b, servido pelo Groq. A resposta também vem com citação de fonte.



MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction
Running · 2026-09-20 23:31:48

Guardian.Service.FileInciden...
Guardian.Process.IncidentR...
Guardian.Operation.FileOutp...
Guardian.Operation.Priority...

[View full details →](#)

RAG Assistant (Grog)

Context: latest investigation (AI Incident Investigator)

Component: Guardian.Operation.PriorityOutputOperation · 60 min window · 2026-09-20 23:29:35

SUMMARY

Component `Guardian.Operation.PriorityOutputOperation` is currently in a `degraded` state (queue=0, messages=66, recent errors=1). Within the last 60 minutes, the component experienced intermittent failures when attempting to write incident output files to `/durable/guardian/out_priority/`, resulting in file open errors (`ERROR #5005`) and failure timeouts (`<Ens>ErrFailureTimeout`).

What is the cause of error #5005?

Ask

Cause of ERROR#5005

`ERROR #5005`: Cannot open file `'/durable/guardian/out_priority/...'` is generated when the Guardian process is unable to open the destination file at the OS level. Both the current investigation and the documented Phase-1 experiment point to **insufficient write permission (or a temporary lock) on the target directory** as the root cause:

* The investigation notes that the error “may be caused by temporary loss of write permissions for the `irisowner` user or file-locking conflicts on the destination path” [the current investigation] .

* In Phase1, the same error was reproduced deliberately by changing the directory permissions to `chmod 555` , which removed write access for `irisowner` . The operation then failed with `ERROR #5005` and no output file was created [Phase1 - Production COS] .

Therefore, **ERROR#5005 indicates that the Guardian process cannot open the file because the OS denies write access to the `/durable/guardian/out_priority/` directory (or the underlying storage is temporarily unavailable/locked).**

Actionable steps to verify and resolve the issue

1. Check the directory's current ownership and permissions

```
`` bash
ls -ld /durable/guardian/out_priority/
```

Confirm that the owner is `irisowner` and that the permission bits include write (`w`) for the owner (e.g., `drwxr-xr-x → 755`).

2. If permissions are too restrictive, restore write access

```
`` bash
chmod 755 /durable/guardian/out_priority/
chown irisowner:irisowner /durable/guardian/out_priority/
```

This matches the fix applied in the Phase-1 scenario where changing from `chmod 555` back to `chmod 755` cleared the error [Phase1 - Production COS] .

3. Verify that no other process holds an exclusive lock on the directory or files

* List open file handles that involve the path:

```
`` bash
lsof +D /durable/guardian/out_priority/
```

* If any non-IRIS process is locking files, stop or restart that process.

4. Confirm the underlying storage is healthy

* Check disk space: `df -h /durable` – ensure there is free space.
* Review mount status: `mount | grep /durable` – look for “`rw`” (read-write) and for any recent remount or error messages in `dmesg / /var/log/syslog` .

5. Examine IRIS system logs for OS-level I/O errors around the failure times

```
`` bash
tail -n 200 /usr/irissys/mgr/messages.log | grep -E "22:34|23:29"
```

Look for entries such as “permission denied”, “filesystem read-only”, or “I/O error”.

6. Test the file-output operation

* Trigger a new incident (or replay the last one) and watch the Guardian logs.

* If the file appears under `/durable/guardian/out_priority/` without error, the issue is resolved.

7. Monitor the component health

* In the Management Portal, navigate to **Guardian -> Operations -> PriorityOutputOperation** (menu path quoted literally if present in your UI) and confirm the status returns to **healthy** and that “recent errors” drops to `0` .

8. If the problem recurs, investigate mount stability

* Review storage subsystem logs (e.g., `SAN/NFS`) for intermittent disconnects.

* Consider adding a watchdog script that alerts when the mount becomes read-only or unavailable.

Summary:

`ERROR#5005` is caused by the Guardian process lacking write permission (or encountering a temporary lock) on the `/durable/guardian/out_priority/` directory. Restoring proper `755` permissions for the `irisowner` user, ensuring the filesystem is mounted read-write and has sufficient space, and verifying no external lock exists will eliminate the error.

Sources: the current investigation (hypotheses on permission/lock issues) and Phase-1

production documentation (chmod555 → error, chmod755 → recovery).

Sources used:

Phase 4 - AI Incident Investigator similarity: 0.624

ix of control characters and text, e.g.
"0 i<Ens>ErrFailureTimeoutPERROR #5005..." — it cannot be shown directly to the user nor passed to the AI prompt without treatment. Solved with \$System.Status.GetErrorText(), confirmed live against real error messages from the Phase 1 failure/recovery experiment.

Phase 3 - RAG Assistant similarity: 0.619

Real errors found and fixed

Evidence Scorecard similarity: 0.614

tigation of Guardian.Operation.FileOutputOperation against the history of the Phase 1 failure/recovery experiment — 20 real events retrieved (including the 3 #5005 error episodes), the analysis correctly separated observations from hypotheses, and flagged as a gap (not as an invented fact) the discrepancy between unavailable health and recent errors=0. Investigation confirmed persisted by a direct SQL query.
- State: confirmed.

Evidence Scorecard similarity: 0.594

VR-002 — Foreign Table in the Community Edition

Phase 1 - Production COS similarity: 0.591

1. Destination broken (chmod 555 on /durable/guardian/out, removing write access from irisowner).
2. Incident INC-003 fired. After ~15s (the framework's default FailureTimeout, confirmed in Ens.BusinessOperation|FailureTimeout = 15, RetryInterval = 5), the Operation records in Ens.MessageHeader.ErrorStatus:
`<Ens>ErrFailureTimeout ... ERROR #5005: Cannot open file '/durable/guardian/out/incident_INC-003.txt'
`
No output file is generated — the failure is real (an operating system error), not faked in the interface.
3. Destination fixed (chmod 755).
4. A new incident (INC-004) flows automatically and successfully — this confirms automatic recovery for new traffic, without restarting the Production.
5. The incident that fa

Second LLM provider (multi-model bonus): the answer is generated by Groq (openai/gpt-oss-120b model), not Gemini - document retrieval still uses the same mechanism as the RAG Assistant (Gemini), without inventing information outside the retrieved context, and answers "I don't know" when similarity with the corpus is low. Current abstention threshold: 0.58 (initial heuristic, see docs/corpus_en/04_PHASE_3_RAG_ASSISTANT.md).

PRINT P20 — RAG Assistant (Groq) respondendo com citação de fonte.

Se alguma resposta não repetir o esperado no dia (por exemplo, se o conteúdo indexado mudou), **não invente**: grave o resultado real e ajuste a fala, nunca a tela.

6. Consertar o destino e mostrar a recuperação (2 minutos)

6.1 Destrancar a pasta

TERMINAL No Terminal 1:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian chmod 755 /durable/guardian/out_priority
```

Em palavras simples: `chmod 755` devolve a permissão de gravar. É o conserto do problema que criamos.

6.2 Mostrar que o destino consertado realmente aceita escrita de novo

Achado ao vivo nesta revisão: a mensagem de recuperação precisa ter a **mesma severidade** que falhou (`CRITICAL` / `HIGH` / `MEDIUM`), não `LOW`. A regra `RouteBySeverity` só manda para `out_priority` quando a severidade é `HIGH`, `CRITICAL` ou `MEDIUM` — uma mensagem `LOW` vai para `out`, a pasta que nunca foi bloqueada, e não prova nada sobre a correção que acabamos de fazer.

TERMINAL No Terminal 1. Comando único, uma linha só:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian sh -c 'F=/durable/guardian/in/demo4.txt; echo "INC-004|IRIS.Service.PaymentGateway|CRITICAL|Critical flow after destination recovery" > $F && chown irisowner:irisowner $F'
```

Em palavras simples: Mesmo formato do passo 3.2, mas agora com severidade `CRITICAL` — a mesma do `INC-003` — para forçar a mensagem a passar de novo por `Guardian.Operation.PriorityOutputOperation`, exatamente o destino que consertamos no passo 6.1. Só assim o teste prova algo: se essa mensagem for gravada em `out_priority`, a correção funcionou de verdade.

TERMINAL Confirme que o arquivo foi escrito no destino certo (comando único):

COMANDO ÚNICO

```
docker exec -i iris-guardian ls -la /durable/guardian/out_priority
```


Em palavras simples: Deve aparecer `incident_INC-004.txt` lá dentro, escrito com sucesso — diferente do `INC-003` na seção 3, que nunca chegou a ser criado porque a pasta estava bloqueada naquele momento.

GUARDIAN Clique em **Monitor** no menu lateral esquerdo (não é preciso esperar 15 segundos).

Em palavras simples: O `INC-004` foi gravado com sucesso na hora. Como `degraded` inclui **erro não recuperado** (o último erro do host ainda não foi seguido de um sucesso no mesmo caminho), os hosts que estavam amarelos voltam a `healthy` **exatamente** quando esta mensagem passa com sucesso pelo `PriorityOutputOperation` — sem depender de tempo. Se você **não** enviar esta mensagem, o Monitor continua amarelo mesmo com a pasta já destrancada, e isso é o comportamento esperado.

O QUE EU DIGO (primeira pessoa)

O sistema aceita e processa o tráfego crítico imediatamente, sem reiniciar nada. Mandeí de propósito a mesma severidade que falhou antes, para provar que o destino realmente voltou a aceitar escrita. E repare no indicador de saúde: ele não voltou a verde por passar o tempo, e sim porque uma mensagem nova concluiu com sucesso exatamente no caminho que estava com erro.



PRINT P21 — Monitor após a recuperação: os quatro hosts de volta em healthy.

6.3 Explicar por que o INC-003 não some sozinho

Em palavras simples: A mensagem `INC-003` falhou **antes** de a pasta ser consertada. O tempo de tentativas já tinha acabado, então essa mensagem específica ficou marcada como falha. Isso é o comportamento normal do IRIS. Mensagens **novas** passam normalmente, sem reiniciar nada.

Reenvio manual (opcional). Duas formas:

PORTAL IRIS Pelo **Message Viewer** (mais fácil para gravar): Management Portal → **Interoperability** → **View** → **Messages** → marque a caixinha da mensagem do INC-003 com erro → clique em **Resend**.

InterSystems™
IRIS Data Platform

Management Portal

[Home](#)
[About](#)
[Help](#)
[Logout](#)

Menu

Server c57ef8318d8f **Namespace** GUARDIAN **User** guardian **Licensed To** InterSystems IRIS Community **Instance** IRIS

Interoperability > Message Viewer

Message Viewer

Search

Cancel

Reset

Resend

Previous

Next

Export

Open in the new UI

Sort Order

Page Size

Newest First

100

Time Format

Page

Complete

1

Basic Criteria

Status

Type

All

Session Start

Start Time

Start ID

End Time

End ID

Source

Target

Extended Criteria

Saved Searches

#	ID	Time Created	Session	Status	Error	Source	Target
1	859	2026-09-19 23:42:00.929	859	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
2	856	2026-09-19 23:39:50.837	856	Error	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
3	853	2026-09-19 23:36:45.690	853	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
4	848	2026-09-19 23:36:40.681	848	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
5	847	2026-09-19 23:36:40.679	847	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
6	846	2026-09-19 12:56:44.761	846	Completed	OK	Ens.ScheduleService	Ens.ScheduleHandler
7	845	2026-09-18 14:22:24.671	845	Completed	OK	Ens.ScheduleService	Ens.ScheduleHandler
8	842	2026-09-17 18:30:24.959	842	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
9	839	2026-09-17 18:27:49.811	839	Error	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci
10	836	2026-09-17 18:27:39.800	836	Completed	OK	Guardian.Service.FileIncidentService	Guardian.Process.Inci

Header

Body

Contents

Trace

<ObjectId>

856

Session Id

856

TargetConfigName

Guardian.Process.IncidentRouterProcess

SourceConfigName

Guardian.Service.FileIncidentService

MessageBodyClassName

Guardian.Messages.IncidentEvent

MessageBodyId

751

TimeCreated

2026-09-19 23:39:50.837

TimeProcessed

2026-09-19 23:40:05.908

Type

Request

Priority

Async

SourceBusinessType

BusinessService

TargetQueueName

Guardian.Process.IncidentRouterProcess

TargetBusinessType

BusinessProcess

ReturnQueueName

CorrespondingMessageId

BusinessProcessId

Description

Invocation

Queue

SuperSession

Resend

0

Status

Error

Is Error?

0

ErrorStatus

OK

Blocked

0

PRINT P22 — Message Viewer com a mensagem do INC-003 marcada e o botão Resend em destaque.

TERMINAL Por comando: troque `<ID_DA_MENSAGEM>` pelo número anotado no passo 3.4 e cole as 4 linhas de uma vez:

BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
set sc=##class(Ens.MessageHeader).ResendMessage(<ID_DA_MENSAGEM>)
write "Resend sc: ",sc,!
halt
EOF
```

Confirme o arquivo `incident_INC-003.txt` aparecendo em `out_priority`.

O QUE EU DIGO (primeira pessoa)

O sistema se recupera sozinho para tráfego novo, sem reiniciar nada, e nada foi escondido ou fingido como sucesso enquanto a mensagem antiga continuava marcada como falha.


7. Bônus implementados (2 a 3 minutos)

7.1 Business Rules: quem decide para onde vai cada incidente

Em palavras simples: Uma **regra de negócio** é uma decisão do tipo "se acontecer isto, faça aquilo" que você edita **visualmente**, sem programar e sem recompilar o resto do sistema. A nossa lê a severidade e escolhe o destino.


O endereço direto da regra não carrega o diagrama sozinho. Ele só preenche o nome na barra de navegação; a área de edição fica vazia até você clicar em **Open**. Por isso, siga os cliques abaixo.

PORTAL IRIS No Management Portal, clique em **Interoperability** (1) no menu esquerdo, depois em **Build** (2), depois em **Business Rules** (3).



PRINT R1 — Caminho de cliques: Interoperability (1) → Build (2) → Business Rules (3), Production Running.


PORTAL IRIS Abre o Rule Editor vazio. Clique no botão **Open** no canto superior direito da tela.



PRINT P23 — Rule Editor vazio com o botão Open em destaque.


PORTAL IRIS No diálogo **Open Rule**, clique em **Guardian** (nome do pacote) → depois em **Rule** → depois em **IncidentRoutingRule**.

Achado ao vivo nesta revisão: o primeiro nível do diálogo é o nome do pacote (**Guardian**), não "Business Rules" — a V3 anterior descrevia esse clique errado.



PRINT P24 — Diálogo Open com o caminho Rule → IncidentRoutingRule (já dentro do pacote Guardian).

A regra carrega assim:



PRINT R2 — Regra RouteBySeverity carregada. Se Severity for HIGH, CRITICAL ou MEDIUM, devolve PriorityOutputOperation; caso contrário (otherwise), devolve FileOutputOperation.

O QUE EU DIGO (primeira pessoa)

Este é o Business Rules Editor do IRIS, um editor visual de regras de negócio. A regra que estou mostrando, *RouteBySeverity*, é a que decide para onde cada incidente vai: se a severidade for *HIGH*, *CRITICAL* ou *MEDIUM*, a regra devolve o nome do *Guardian.Operation.PriorityOutputOperation*, o destino prioritário que acabei de testar na falha controlada. Para qualquer outra severidade, ela devolve o *Guardian.Operation.FileOutputOperation*, o destino normal.

O ponto importante aqui é que essa decisão de roteamento é configurável visualmente, sem recompilar nada. Se eu quisesse adicionar uma quarta severidade ou trocar o destino, eu editaria essa regra aqui e recompilaria só ela, sem tocar no código dos outros componentes. É exatamente essa regra que decidi, nas seções 3 e 6, mandar tanto o *INC-003* quanto o *INC-004* para o mesmo destino prioritário — os dois são *CRITICAL*. A diferença entre um falhar e o outro funcionar não veio da regra, veio do estado da pasta de destino em cada momento.

7.2 Busca híbrida (só falar, sem clicar)

Em palavras simples: Você não clica em nada. Só explica como o RAG Assistant achou os trechos certos em todas as perguntas da seção 5. **Vetorial** = busca por significado. **Lexical** = busca por palavra exata. Juntar as duas dá resultado melhor que qualquer uma sozinha.

O QUE EU DIGO (primeira pessoa)

A busca do RAG Assistant não usa só uma técnica, ela combina duas. A primeira é busca vetorial: a pergunta do usuário é transformada num vetor numérico, um *embedding*, e comparada por similaridade com o vetor de cada trecho da documentação. Isso captura o significado da pergunta, mesmo que as palavras exatas sejam diferentes das do documento. A segunda é busca lexical, usando o índice de texto completo nativo do IRIS, o *iFind*. Isso captura correspondências exatas de palavras-chave, que a busca por significado às vezes não prioriza.

Os dois rankings são combinados por um método chamado *Reciprocal Rank Fusion*: cada busca contribui com até 15 candidatos, e a posição de cada trecho nos dois rankings é combinada matematicamente para montar os 5 trechos finais que a IA usa para responder.

Na prática, isso significa: se a pergunta usa um termo técnico exato que aparece literalmente na documentação, a busca lexical ajuda a garantir que esse trecho apareça; se a pergunta é feita com outras palavras, a busca vetorial ainda encontra o trecho certo pelo significado. A decisão de abstenção, aliás, continua baseada só na melhor similaridade vetorial pura. Ela não muda por causa da fusão híbrida, para não invalidar a calibração que testei.

7.3 Segunda Production: PublicHealth (opcional)

Existe uma segunda Production, *PublicHealthProduction*, que consome uma API pública real (*disease.sh*) e trata indisponibilidade sem inventar dados. Só uma Production roda por vez, então mostrar ao vivo exige parar a atual. Decida se vale o tempo do vídeo ou se só cita.

TERMINAL Para trocar para a PublicHealth (cole as 4 linhas de uma vez):

BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
do ##class(Ens.Director).StopProduction()
set sc=##class(Ens.Director).StartProduction("Guardian.Production.PublicHealthProduction")
write "Start PublicHealth sc: ",sc,!
halt
EOF
```

TERMINAL Para **voltar** à Production principal (obrigatório se for gravar mais alguma coisa depois):


BLOCO COLADO DE UMA VEZ (VÁRIAS LINHAS DE PROPÓSITO)

```
docker exec -i iris-guardian iris session IRIS -U GUARDIAN <<'EOF'
do ##class(Ens.Director).StopProduction()
set sc=##class(Ens.Director).RecoverProduction()
set sc=##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction")
write "Start Guardian sc: ",sc,!
halt
EOF
```

8. Metodologia com IA (1 minuto)

8.1 Mostrar a pasta de prompts

TERMINAL No Finder (ou no editor de código), abra a pasta `entregaveis/Prompts/` do projeto. São 12 arquivos com a sequência real de prompts por fase, com os erros reais encontrados e corrigidos. Você **não** precisa ler nada; só aponte que existe e abra um arquivo rapidamente como exemplo.



PRINT P25 — Pasta entregaveis/Prompts com os 12 arquivos.

9. Encerramento (30 a 45 segundos)

9.1 Falar o fechamento

GUARDIAN Deixe o Guardian aberto no **Monitor**.

O QUE EU DIGO (primeira pessoa)

Esse foi o IRIS Production Guardian: um Production Monitor em tempo real, um AI Incident Investigator que fundamenta hipóteses em evidência sem executar nada sozinho, e um RAG Assistant que cita a fonte e sabe dizer que não sabe. Além do escopo obrigatório, entreguei quatro bônus: roteamento por Business Rules, busca híbrida vetorial e lexical, um segundo provedor de IA para geração de resposta, e uma segunda produção que integra uma API pública de saúde. Todo o código está aberto no repositório GitHub, o link está na descrição deste vídeo. Obrigado por assistir.

Link para mostrar na tela: <https://github.com/sergiofsq/iris-production-guardian>

O link do vídeo publicado e o link do Open Exchange **ainda não existem** na hora da gravação, então não dá para citá-los. Preencha depois em `entregaveis/Artigo_Comunidade_PT.md`.

Limpeza depois de gravar

L.1 Parar o loop

TERMINAL No Terminal 2, pressione **Ctrl+C**. Se ele estiver em segundo plano, no Terminal 1: `pkill -f healthy_traffic_loop` (OU `pkill -f "durable/guardian/in"` se você colou o bloco em vez de rodar o script).

L.2 Limpar as pastas

TERMINAL No Terminal 1:

COMANDO ÚNICO (UMA LINHA SÓ)

```
docker exec -i iris-guardian sh -c 'D=/durable/guardian; chmod 755 $D/out $D/out_priority && rm -rf $D/in/* $D/archive/* $D/out/* $D/out_priority/*'
```

Em palavras simples: O `chmod 755` vem antes do `rm`: se a pasta `out_priority` ainda estiver em 555, o `rm` falha com "Permission denied".

L.3 Deixar a Production certa rodando

Confirme que a Production ativa é `Guardian.Production.GuardianProduction` e não a `PublicHealthProduction` (se você testou o item 7.3).

Checklist final antes de publicar

- Nenhuma chave de API, senha ou dado pessoal visível em nenhum frame (revise aberturas de terminal e a barra de favoritos).
- Interface e texto em inglês na tela, nas quatro páginas do Guardian (botão EN).
- Nenhum corte esconde uma espera real nem sugere um tempo falso de recuperação.
- Depois de publicado, preencher o link do vídeo em `entregaveis/Artigo_Comunidade_PT.md`.