

Roteiro Visual de Gravação

Passo a passo com telas reais e indicação de onde clicar

-  = onde clicar / o que observar em cada tela
- Todas as telas abaixo foram capturadas ao vivo, na própria aplicação rodando, com um cenário real de falha e recuperação — não são mockups.
- Comandos de terminal (fundo azul-escuro) rodam no seu Mac, fora do container.
- Este PDF acompanha (não substitui)
`docs/planejamento/08_ROTUIRO_GRAVACAO_VIDEO.md`,
que tem todos os comandos completos e falas sugeridas por extenso.

0. Antes de gravar

- ☐ Ocultar a barra de favoritos do navegador (ou usar janela anônima).
- ☐ Não abrir a tela de Credentials do Management Portal (é onde ficam as chaves de API).
- ☐ `docker start iris-guardian` se o container não estiver rodando.
- ☐ Confirmar Production **Running** (ver seção "Nota" no arquivo .md se não estiver).
- ☐ Limpar os diretórios de mensagens (comando no arquivo .md, seção 0).
- ☐ Dar um refresh forçado no navegador (Cmd+Shift+R) antes de começar.
- ☐ Deixar o idioma em **EN** — veja onde clicar abaixo.

Botão de idioma (canto superior da sidebar)

🔴 clique aqui até o botão mostrar **EN**

The screenshot shows the 'Production Monitor' interface. In the top-left sidebar, there is a language dropdown menu with 'PT' selected and circled in red. Below it, the 'PRODUCTION MONITOR' section shows the status of various components. The main area displays three columns: 'INBOUND HOSTS (SERVICE)', 'PROCESSING HOSTS (PROCESS)', and 'OUTBOUND HOSTS (OPERATION)'. Each column contains a card for a specific component, showing its status (HEALTHY or DEGRADED), queue size, message count, and recent errors. A legend at the bottom explains the status indicators: healthy (green dot), degraded (yellow dot), unavailable (grey dot), and unknown (grey dot).

Production Monitor
Production: `Guardian.Production.GuardianProduction` · State: **Running** · Collected at: **2026-09-17 18:25:08** (refreshes every 10s)

INBOUND HOSTS (SERVICE)	PROCESSING HOSTS (PROCESS)	OUTBOUND HOSTS (OPERATION)
Guardian.Service.FileIncidentService HEALTHY Queue: 0 · Messages: 28 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0	Guardian.Process.IncidentRouterProcesses DEGRADED Queue: 0 · Messages: 87 · Recent errors: 1 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0	Guardian.Operation.FileOutputOperations HEALTHY Queue: 0 · Messages: 38 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0
		Guardian.Operation.PriorityOutputOperations DEGRADED Queue: 0 · Messages: 21 · Recent errors: 1 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

States: **healthy** = no pending queue and no recent error · **degraded** = pending queue or error in the last 900 seconds · **unavailable** = host disabled or Production stopped · **unknown** = no message recorded yet for this host (absence of data is not health) · **stuck** = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (`/api/guardian/status`) - no independent scheduled collector in this v1.

1. Abertura (30-60s)

- 1 Slide simples ou a própria tela do Monitor, parada, antes de navegar.

Fala: apresentar o projeto (IRIS Production Guardian), os três módulos (Production Monitor, AI Incident Investigator, RAG Assistant), e que a aplicação roda inteiramente sobre InterSystems IRIS.

2. Production saudável, tráfego em tempo real

- 1 Abrir o Production Monitor — `Guardian.UI.MonitorPage.cls`.
- 2 Numa segunda janela de terminal, iniciar o loop de tráfego contínuo:

```
sh docs/experiments/loop_trafego_saudavel.sh
```

Deixar rodando do início ao fim da gravação (seções 2 a 7).

Fala: "aqui está o estado saudável, com tráfego real entrando continuamente — vou guardar essa imagem para comparar depois da falha."

Estado saudável — todos os hosts "healthy"

The screenshot displays the 'Production Monitor' interface. On the left is a dark sidebar with navigation links: 'MONITOR' (selected), 'INVESTIGATOR', 'RAG ASSISTANT (GEMINI)', and 'RAG ASSISTANT (GROQ)'. Below these are 'PRODUCTION MONITOR' details, including a status bar with green dots for 'Guardian.Service.FileIncident...', 'Guardian.Process.IncidentR...', and 'Guardian.Operation.FileOutp...', and a grey dot for 'Guardian.Operation.Priority...'. A 'View full details' link is at the bottom of the sidebar.

The main content area is titled 'Production Monitor' and shows 'Production: Guardian.Production.GuardianProduction · State: Running · Collected at: 2026-09-17 18:27:44 (refreshes every 10s)'. It is divided into three columns: 'INBOUND HOSTS (SERVICE)', 'PROCESSING HOSTS (PROCESS)', and 'OUTBOUND HOSTS (OPERATION)'. Each column contains one or more host cards. All cards show a 'HEALTHY' status in a green box. The 'Guardian.Operation.PriorityOutputOperation' card shows an 'UNKNOWN' status in a grey box.

Below the host cards, a legend explains the status codes: **healthy** = no pending queue and no recent error; **degraded** = pending queue or error in the last 900 seconds; **unavailable** = host disabled or Production stopped; **unknown** = no message recorded yet for this host (absence of data is not health); **stuck** = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (/api/guardian/status) - no independent scheduled collector in this v1.

Category	Host Name	Status	Queue	Messages	Recent errors	Queue trend (10 samples)
INBOUND HOSTS (SERVICE)	Guardian.Service.FileIncidentService	HEALTHY	0	1	0	0, 0, 0, 0, 0, 0, 0, 0, 0, 0
PROCESSING HOSTS (PROCESS)	Guardian.Process.IncidentRouterProcesses	HEALTHY	0	3	0	0, 0, 0, 0, 0, 0, 0, 0, 0, 0
OUTBOUND HOSTS (OPERATION)	Guardian.Operation.FileOutputOperations	HEALTHY	0	2	0	0, 0, 0, 0, 0, 0, 0, 0, 0, 0
	Guardian.Operation.PriorityOutputOperation	UNKNOWN	0	0	0	0, 0, 0, 0, 0, 0, 0, 0, 0, 0

3. Falha controlada

1 Quebrar o destino ao vivo:

```
docker exec -i iris-guardian chmod 555 /durable/guardian/out_priority
```

2 Disparar o incidente CRITICAL que vai falhar:

```
docker exec -i iris-guardian sh -c \
'echo "INC-003|IRIS.Service.PaymentGateway|CRITICAL|Simulated write failure at
destination" > /durable/guardian/in/demo3.txt && \
chown irisowner:irisowner /durable/guardian/in/demo3.txt'
```

3 Esperar ao vivo ~15-20s (FailureTimeout real, não cortar no vídeo).

Fala: "note que o tráfego normal continua passando sem problema — só o caminho de incidentes críticos foi afetado, a falha é isolada, não derrubou a Production inteira."

Host de saída prioritária "degraded" — os outros continuam "healthy"

Comparar com a tela anterior: FileIncidentService e FileOutputOperation continuam verdes; só IncidentRouterProcess e PriorityOutputOperation (o caminho da falha) ficam amarelos.

> PT

MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction
Running · 2026-09-17 18:28:05

Guardian.Service.FileInciden...
Guardian.Process.IncidentR...
Guardian.Operation.FileOutp...
Guardian.Operation.Priority...
View full details →

Production Monitor

Production: Guardian.Production.GuardianProduction · State: Running · Collected at: 2026-09-17 18:28:05 (refreshes every 10s)

INBOUND HOSTS (SERVICE)

Guardian.Service.FileIncidentService
HEALTHY
Queue: 0 · Messages: 2 · Recent errors: 0
queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

PROCESSING HOSTS (PROCESS)

Guardian.Process.IncidentRouterProcesses
DEGRADED
Queue: 0 · Messages: 6 · Recent errors: 1
queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

OUTBOUND HOSTS (OPERATION)

Guardian.Operation.FileOutputOperation
HEALTHY
Queue: 0 · Messages: 2 · Recent errors: 0
queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

Guardian.Operation.PriorityOutputOperation
DEGRADED
Queue: 0 · Messages: 2 · Recent errors: 1
queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0


States: healthy = no pending queue and no recent error · degraded = pending queue or error in the last 900 seconds · unavailable = host disabled or Production stopped · unknown = no message recorded yet for this host (absence of data is not health) · stuck = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (/api/guardian/status) - no independent scheduled collector in this v1.

4. AI Incident Investigator

- 1 Abrir `Guardian.UI.InvestigatorPage.cls`.
- 2 Selecionar o componente e clicar em **Investigate** — veja onde abaixo.

Antes de clicar

- selecionar o componente aqui, depois clicar no botão Investigate



Resultado — evidência real coletada

Fala: ler para a câmera a separação entre observação (o que os dados mostram), hipótese (causa provável) e lacunas (o que não dá para afirmar). Não existe botão de "corrigir automaticamente" — a decisão é sempre humana.

⚠ Atenção para o dia da gravação: a captura abaixo foi feita depois de muitos testes seguidos nesta sessão, e o Gemini free-tier (20 chamadas/dia) já tinha esgotado a cota — por isso a caixa "Analysis" mostra um erro 429 em vez do texto da IA. A seção "Events in window" acima dela (evidência real coletada) continua 100% válida como exemplo. Na sua gravação, com a cota fresca, a caixa Analysis deve mostrar o texto normal (observação/hipótese/lacunas). Se aparecer esse mesmo erro 429, é só esperar (a cota reseta) ou fazer menos ensaios antes da gravação valendo.



MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction
Running · 2026-09-17 18:25:38

- Guardian.Service.FileInciden... ●
- Guardian.Process.IncidentR... ●
- Guardian.Operation.FileOutp... ●
- Guardian.Operation.Priority... ●

View full details →

AI Incident Investigator

Real evidence (metrics, events and documentation) + AI-assisted analysis. Read-only - no automatic remediation.

Component Guardian.Operation.PriorityOutputOperation (Operation)

Window (minutes)

60

Investigate

CURRENT HEALTH

DEGRADED Queue: 0 · Messages: 23 · Recent errors: 2

EVENTS IN WINDOW (6)

- msg #832 · 2026-09-17 18:25:34.721 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'
- msg #831 · 2026-09-17 18:25:19.675 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success
- msg #823 · 2026-09-17 18:24:19.665 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
ERROR <Ens>ErrFailureTimeout: FailureTimeout of 15 seconds exceeded in Guardian.Operation.FileOutputOperation; status from last attempt was ERROR #5005: Cannot open file '/durable/guardian/out_priority/incident_INC-003.txt'
- msg #822 · 2026-09-17 18:24:04.588 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success
- msg #814 · 2026-09-17 18:22:14.494 · Guardian.Process.IncidentRouterProcess → Guardian.Operation.PriorityOutputOperation
success
- msg #815 · 2026-09-17 18:22:14.494 · Guardian.Operation.PriorityOutputOperation → Guardian.Process.IncidentRouterProcess
success

ANALYSIS

Could not generate the analysis right now (Gemini generate HTTP 429: You exceeded your current quota, please check your plan and billing details. For more information on this error, head to: <https://ai.google.dev/gemini-api/docs/rate-limits>. To monitor your current usage, head to: <https://ai.dev/rate-limit>.
* Quota exceeded for metric: generativelanguage.googleapis.com/generate_content_free_tier_requests, limit: 20, model: gemini-3.6-flash
Please retry in 19.943987032s.). The evidence collected below is still available for manual review.

RELATED DOCUMENTATION

Fase 1 - Production COS

similarity: 0.800

- Destino quebrado (chmod 555 em /durable/guardian/out , removendo escrita de irisowner).
- Incidente INC-003 disparado. Após ~15s (FailureTimeout padrão do framework, confirmado em Ens.BusinessOperation || FailureTimeout = 15 , RetryInterval = 5), a Operation registra em Ens.MessageHeader.ErrorStatus :
''
<Ens>ErrFailureTimeout ... ERROR #5005: Cannot open file
'/durable/guardian/out/incident_INC-003.txt'
'
Nenhum arquivo de saída é gerado — a falha é real (erro de sistema operacional), não fingida na interface.
- Destino corrigido (chmod 755).
- Um incidente novo (INC-004) flui automaticamente com sucesso — confirma recuperação automática para tráfego novo, sem reiniciar a Production.
- O incidente que falhou

Fase 4 - AI Incident Investigator

similarity: 0.733

Investigação de Guardian.Operation.FileOutputOperation contra o histórico real do experimento de falha/recuperação da Fase 1 (janela grande o suficiente para cobrir os dados de 09/09/2026):

Fase 1 - Production COS

similarity: 0.728

- Production iniciada: ##class(Ens.Director).StartProduction("Guardian.Production.GuardianProduction") → %Status OK, estado confirmado "running" via Ens.Director.GetProductionStatus .
- Arquivo depositado em /durable/guardian/in/demo1.txt :
''
INC-001|IRIS.Service.OrderIngest|HIGH|Fila de mensagens acima do limite configurado
'
3. Após o intervalo de polling do adaptador (5s), o arquivo:
- desapareceu de in ;
- apareceu arquivado em archive/demo1.txt_2026-09-09_17:28:15.298 ;
- gerou out/incident_INC-001.txt com o conteúdo:
''
INC-001|IRIS.Service.OrderIngest|HIGH|Fila de mensagens acima do limite configurado|2026-09-09
17:28:15|Guardian.Process.IncidentRouterProcess|2026-09-09 17:28:15
'
Os dois últimos campos (ProcessedBy ,

Scorecard de Evidencias

similarity: 0.717

- Prova: destino da Operation (/durable/guardian/out) tornado indisponível (chmod 555); incidente disparado; erro real capturado em Ens.MessageHeader.ErrorStatus (ERROR #5005: Cannot open file...,

<Ens>ErrFailureTimeout após 15s). Destino corrigido; tráfego novo recupera automaticamente; mensagem afetada recuperada manualmente via Ens.MessageHeader.ResendMessage .

- Evidência: roteiro reproduzível e validado duas vezes do zero em docs/experiments/01_falha_recuperacao_producao.md ; detalhe completo em 02_FASE_1_PYPROD_INTEROPERABILITY.md §5.

- Estado: **confirmado**. Cobre o "Aceite proposto" do Production Monitor (contexto, seção 2): falha rastreável até o evento original, recuperação visível (automática e manual).

Fase 1 - Production COS similarity: 0.708

| Classe | Papel | Adaptador |

|---|---|---|

| Guardian.Messages.IncidentEvent | Mensagem (Ens.Request) com dados de um incidente sintético | — |

| Guardian.Service.FileIncidentService | Business Service — lê arquivos .txt (um incidente por linha, campos separados por \ |) | EnsLib.File.InboundAdapter |

| Guardian.Process.IncidentRouterProcess | Business Process (código, não BPL) — preenche ProcessedBy / ProcessedAt e roteia para a Operation | — |

| Guardian.Operation.FileOutputOperation | Business Operation — grava o incidente processado como arquivo de saída | EnsLib.File.OutboundAdapter |

| Guardian.Production.GuardianProduction | Production que conecta os três hosts acima | — |


Analysis generated by AI (Google Gemini) using only the real evidence collected above - it does not invent events or a confidence percentage, and keeps observation separate from hypothesis. Read-only investigation - no correction is applied automatically.

5. RAG Assistant — Gemini e Groq

- 1 Abrir `Guardian.UI.RAGPage.cls` (Gemini) ou `Guardian.UI.RAGAltPage.cls` (Groq) — layout idêntico nos dois.
- 2 Digitar a pergunta e clicar em **Ask** — veja onde abaixo.

Antes de perguntar (mesmo layout nas duas páginas)

○ campo de pergunta (já vem com uma sugestão automática da última investigação — apague e digite a pergunta calibrada abaixo) e botão Ask. O aviso azul no topo também mostra o erro de cota da seção 4 — normal, é o mesmo dado real.



Exemplo real de resposta — "What is causing error #5005?"

Capturado ao vivo na página Groq (a mesma pergunta na página Gemini esbarrou na cota diária esgotada durante os testes, ver aviso acima — o comportamento visual é idêntico nas duas, só o provedor de geração muda). Resposta real com citação de fonte, ligando ao erro gerado na seção 3, mais passo a passo de correção sugerido. Abrir a fonte citada na tela para mostrar que não é invenção.



MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction
Running · 2026-09-17 18:25:49

- Guardian.Service.FileInciden... ●
- Guardian.Process.IncidentR... ●
- Guardian.Operation.FileOutp... ●
- Guardian.Operation.Priority... ●

[View full details →](#)

RAG Assistant (Groq)

Context: latest investigation (AI Incident Investigator)

Component: Guardian.Operation.PriorityOutputOperation · 60 min window · 2026-09-17 18:25:40

Could not generate the analysis right now (Gemini generate HTTP 429: You exceeded your current quota, please check your plan and billing details. For more information on this error, head to: <https://ai.google.dev/gemini-api/docs/rate-limits>. To monitor your current usage, head to: <https://ai.dev/rate-limit>.

* Quota exceeded for metric: generativelanguage.googleapis.com/generate_content_free_tier_requests, limit: 20, model: gemini-3.6-flash

Please retry in 19.943987032s.). The evidence collected below is still available for manual review.

What is causing error #5005?

Ask

Cause of error#5005

The error is raised when the `Guardian.Operation.FileOutputOperation` tries to write the incident file `/durable/guardian/out/incident_INC-003.txt` but the directory does not allow write access for the `irisowner` user. The directory was set to read-only (`chmod 555`), so the operation fails with:

```
''
<Ens>ErrFailureTimeout ... ERROR #5005: Cannot open file
'/durable/guardian/out/incident_INC-003.txt'
'
```

[Source: *Fase 1 – Production COS*]

Actionable steps to fix the problem (in order)

1. Verify the current permissions of the output directory

```
` bash
ls -ld /durable/guardian/out
`
```

Confirm that the mode shows `dr-xr-xr-x (555)` and that the owner is `irisowner`.

2. Restore write permission for the owner (irisowner)

```
` bash
chmod 755 /durable/guardian/out
`
```

This gives the owner read/write/execute (`7`) and group/others read/execute (`5`).

3. Confirm the permission change

```
` bash
ls -ld /durable/guardian/out
`
```

The mode should now be `drwxr-xr-x (755)`.

4. Optionally, ensure the correct ownership (if it was altered)

```
` bash
chown irisowner:irisowner /durable/guardian/out
`
```

5. Re-run the failed operation or let the next incident flow

– If you can manually trigger the operation, do so and watch the logs for the absence of error #5005.
– Otherwise, wait for the next automatic incident; after the permission fix, a new incident (`INC-004`) succeeded without error, confirming the fix.

[Source: *Fase 1 – Production COS*]

6. Monitor the Production Monitor for any further `ErrorStatus <= 1` entries to ensure no other file-system-related errors appear.

[Source: *Fase 2 – Production Monitor*]

7. Document the change in the change-management system (e.g., note “Fixed write permission on `/durable/guardian/out` to resolve error #5005”).

Summary:

Error #5005 is caused by insufficient write permissions on the output directory `/durable/guardian/out`. Restoring write permission (`chmod 755`) for the `irisowner` account resolves the issue and allows subsequent incidents to be written successfully.

Sources used:

Fase 4 - AI Incident Investigator

similarity: 0.598

m %\$Status serializado (mistura de caracteres de controle e texto, ex. "0 i<Ens>ErrFailureTimeoutPERROR #5005...") – não dá pra mostrar direto ao usuário nem passar pro prompt da IA sem tratar. Resolvido com `$System.Status.GetErrorText()`, confirmado ao vivo contra mensagens reais de erro do experimento de falha/recuperação da Fase 1.

Fase 1 - Production COS

similarity: 0.594

1. Destino quebrado (`chmod 555` em `/durable/guardian/out`, removendo escrita de `irisowner`).
2. Incidente `INC-003` disparado. Após ~15s (`FailureTimeout` padrão do framework, confirmado em `Ens.BusinessOperation||FailureTimeout = 15, RetryInterval = 5`), a `Operation` registra em `Ens.MessageHeader.ErrorStatus`:
``
`<Ens>ErrFailureTimeout ... ERROR #5005: Cannot open file`
`'/durable/guardian/out/incident_INC-003.txt'`
``
Nenhum arquivo de saída é gerado — a falha é real (erro de sistema operacional), não fingida na interface.
3. Destino corrigido (`chmod 755`).
4. Um incidente **novo** (`INC-004`) flui automaticamente com sucesso — confirma recuperação automática para tráfego novo, sem reiniciar a `Production`.
5. O incidente que falhou

Scorecard de Evidencias

similarity: 0.594

real de `Guardian.Operation.FileOutputOperation` contra o histórico do experimento de falha/recuperação da Fase 1 — 20 eventos reais recuperados (incluindo os 3 episódios de erro `#5005`), análise corretamente separou observações de hipóteses, e sinalizou como **lacuna** (não como fato inventado) a discrepância entre saúde `unavailable` e erros recentes=`0`. Investigação confirmada persistida por consulta SQL direta.
- Estado: **confirmado**.

Fase 4 - AI Incident Investigator

similarity: 0.586

3. Refactor no RAG: `Guardian.RAG.Query.Retrieve`

`Guardian.RAG.Query.Ask` fazia recuperação + geração numa única chamada. Para o Investigator reaproveitar a busca híbrida sem disparar uma geração de texto desnecessária (a geração final é feita uma única vez, com toda a evidência junta, no `Analyzer`), a recuperação foi extraída para um método próprio, `Retrieve(pQuestion)`, retornando `{sources, bestSimilarity, contextText}`. `Ask` passou a chamar `Retrieve` internamente e manter exatamente o mesmo comportamento público — testado após o refactor: mesma pergunta ("erro #5005"), mesmo resultado (`abstained=0`, similaridade 0.677, 5 fontes) de antes do refactor.

4. Bugs reais encontrados e corrigidos

Fase 2 - Production Monitor

similarity: 0.573

`, TimeCreated, ErrorStatus ) |`
`| Detecção de erro por linha | ErrorStatus <> 1' — testado contra dados reais (2 erros reais do experimento de falha, seção 07 do scorecard, foram corretamente contados) |`

Second LLM provider (multi-model bonus): the answer is generated by Groq (openai/gpt-oss-120b model), not Gemini - document retrieval still uses the same mechanism as the RAG Assistant (Gemini), without inventing information outside the retrieved context, and answers "I don't know" when similarity with the corpus is low. Current abstention threshold: 0.58 (initial heuristic, see docs/planejamento/04_FASE_3_RAG_ASSISTANT.md).

Pergunta fora do corpus — abstenção

Fala: perguntar algo sem relação nenhuma com o projeto (ex.: "What is the recipe for chocolate cake?"). O sistema responde que não sabe, em vez de inventar — "aqui o sistema se recusa a responder porque não há nada no corpus sobre isso, isso é a abstenção calibrada, não um bug." (limiar 0.58 de similaridade — perguntas relevantes testadas ficaram entre 0.67-0.76, as irrelevantes entre 0.51-0.52, sem ambiguidade).

Trocar entre Gemini e Groq (bônus multimodelo)

- link na sidebar para o RAG Assistant (Groq)

PT

 PRODUCTION GUARDIAN

MONITOR

INVESTIGATOR

RAG ASSISTANT (GEMINI)

RAG ASSISTANT (GROQ)

PRODUCTION MONITOR

Guardian.Production.GuardianProduction Running · 2026-09-17 18:25:46

Guardian.Service.FileInciden... ●

Guardian.Process.IncidentR... ●

Guardian.Operation.FileOutp... ●

Guardian.Operation.Priority... ●

View full details →

RAG Assistant (Gemini)

Context: latest investigation (AI Incident Investigator)

Component: Guardian.Operation.PriorityOutputOperation · 60 min window · 2026-09-17 18:25:40

Could not generate the analysis right now (Gemini generate HTTP 429: You exceeded your current quota, please check your plan and billing details. For more information on this error, head to: <https://ai.google.dev/gemini-api/docs/rate-limits>. To monitor your current usage, head to: <https://ai.dev/rate-limit>.
* Quota exceeded for metric: generativelanguage.googleapis.com/generate_content_free_tier_requests, limit: 20, model: gemini-3.6-flash
Please retry in 19.943987032s.). The evidence collected below is still available for manual review.

Ask

Could not reach the AI model right now (Gemini generate HTTP 429: You exceeded your current quota, please check your plan and billing details. For more information on this error, head to: <https://ai.google.dev/gemini-api/docs/rate-limits>. To monitor your current usage, head to: <https://ai.dev/rate-limit>.
* Quota exceeded for metric: generativelanguage.googleapis.com/generate_content_free_tier_requests, limit: 20, model: gemini-3.6-flash
Please retry in 12.096190822s.). Try again shortly.

Answers generated by AI (Google Gemini) using only the documents indexed for this project - it does not invent information outside the retrieved context, and answers "I don't know" when similarity with the corpus is low. Current abstention threshold: 0.58 (initial heuristic, see docs/planejamento/04_FASE_3_RAG_ASSISTANT.md).

Fala: repetir a pergunta 1 na página Groq — retrieval/embeddings são os mesmos (Gemini); só o modelo de geração muda (Groq, openai/gpt-oss-120b). Ver a resposta real capturada acima.

6. Corrigir e mostrar recuperação

- 1 Corrigir a permissão:

```
docker exec -i iris-guardian chmod 755 /durable/guardian/out_priority
```

- 2 Mandar tráfego novo e mostrar o Monitor voltando a "healthy":

```
docker exec -i iris-guardian sh -c \  
'echo "INC-004|IRIS.Service.PaymentGateway|LOW|Normal flow after destination recovery" >  
/durable/guardian/in/demo4.txt && \  
chown irisowner:irisowner /durable/guardian/in/demo4.txt'
```

Fala: "o sistema se recupera sozinho para tráfego novo, sem reiniciar nada — e nada foi escondido ou fingido como sucesso enquanto a mensagem antiga continuava marcada como falha."

Recuperação real

O badge "degraded" nos dois hosts do caminho da falha pode continuar laranja por até 15 minutos após o conserto — é o `ErrorWindowSeconds` do design (erro recente = últimos 900s), não um sinal de que a correção falhou. A prova real de recuperação é o **tráfego novo chegando sem erro** (mensagem INC-004 abaixo), não a cor do badge sozinha.

The screenshot shows the 'Production Monitor' dashboard for 'Guardian'. The interface is divided into three main sections: INBOUND HOSTS (SERVICE), PROCESSING HOSTS (PROCESS), and OUTBOUND HOSTS (OPERATION). Each section displays the status of a specific component, including its name, health status (HEALTHY or DEGRADED), and queue/message statistics.

Production Monitor
Production: `Guardian.Production.GuardianProduction` · State: `Running` · Collected at: `2026-09-17 18:30:36` (refreshes every 10s)

INBOUND HOSTS (SERVICE)	PROCESSING HOSTS (PROCESS)	OUTBOUND HOSTS (OPERATION)
Guardian.Service.FileIncidentService HEALTHY Queue: 0 · Messages: 3 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0	Guardian.Process.IncidentRouterProcesses DEGRADED Queue: 0 · Messages: 9 · Recent errors: 1 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0	Guardian.Operation.FileOutputOperation HEALTHY Queue: 0 · Messages: 4 · Recent errors: 0 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0
		Guardian.Operation.PriorityOutputOperation DEGRADED Queue: 0 · Messages: 2 · Recent errors: 1 queue trend (10 samples): 0, 0, 0, 0, 0, 0, 0, 0, 0, 0

States: **healthy** = no pending queue and no recent error · **degraded** = pending queue or error in the last 900 seconds · **unavailable** = host disabled or Production stopped · **unknown** = no message recorded yet for this host (absence of data is not health) · **stuck** = positive queue that hasn't drained in the last 3 persisted samples. Time series persisted on each load of this page or API call (`/api/guardian/status`) - no independent scheduled collector in this v1.

7. Bônus, metodologia e encerramento

- 1 **Business Rules** — abrir o Rule Editor (URL no arquivo .md, seção 7) e mostrar que a severidade decide o destino sem recompilar nada.
- 2 **Hybrid search** — mencionar (não precisa demonstrar).
- 3 **PublicHealth bonus** — mencionar a segunda Production (comandos completos no arquivo .md, seção 7, se quiser mostrar ao vivo).
- 4 **Metodologia** — mostrar a pasta entregaveis/Prompts/.
- 5 **Encerramento** — resumir os três módulos, os bônus, e onde encontrar o repositório.

Limpeza pós-gravação

- 1 Parar o loop de tráfego (Ctrl+C).
- 2 Limpar os diretórios:

```
docker exec -i iris-guardian sh -c \  
'rm -f /durable/guardian/in/* /durable/guardian/archive/* /durable/guardian/out/*  
/durable/guardian/out_priority*'
```

- 3 Confirmar a Production **Running** de novo.

Gerado a partir de uma execução real da aplicação em 17/09/2026 — telas e respostas de IA reais, não mockups. Consulte docs/planejamento/08_ROTUIRO_GRAVACAO_VIDEO.md para os comandos completos, URLs e checklist final antes de publicar.