

MANUAL DE USO

IRIS Production Guardian

Monitoramento da Production e investigação assistida por IA

Este manual ensina a navegar pela aplicação, interpretar cada campo e usar o Investigator e o RAG Assistant. As capturas mostram o ambiente real em 12 de setembro de 2026; os números e as respostas podem mudar a cada consulta.

O caminho de uso é Monitor → Investigator → RAG Assistant. Alterações operacionais, como iniciar a Production, são realizadas no Portal de Administração do IRIS.

Edição 1 • 12 de setembro de 2026

Identificação	Descrição
Aplicação	IRIS Production Guardian
Ambiente	Local • namespace GUARDIAN
Público	Operadores, suporte e administradores
Cobertura	Quatro telas, indicadores, campos de entrada, resultados, fontes e orientações para indisponibilidade

Como consultar

Acesso e navegação: página 2. Monitor: páginas 3 a 5. Investigator: páginas 6 a 8. RAG Assistant: páginas 9 a 11. Roteiro operacional e referências: página 12.

1 Acesso e navegação

No computador em que o IRIS está publicado, abra o endereço abaixo. Se aparecer uma solicitação de login, use seu usuário autorizado do IRIS.

<http://localhost:53773/csp/guardian/Guardian.UI.MonitorPage.cls>

O endereço localhost se refere ao próprio computador. Em outra máquina, é necessário o endereço do servidor fornecido pelo administrador.



Figura 1. Opções do menu lateral. O resumo da Production aparece abaixo delas.

Campo ou elemento	O que representa e como usar
Monitor	Abre a visão completa dos componentes, filas, mensagens e erros.
Investigator	Abre o formulário para investigar um componente em uma janela de tempo.
RAG Assistant (Gemini)	Consulta a documentação indexada e pode usar a última investigação como contexto.
RAG Assistant (novo modelo)	Segunda interface de consulta. Nesta edição, usa o mesmo Gemini; não é um provedor alternativo ativo.
Production Monitor lateral	Mostra o nome da Production, estado, horário de coleta e uma linha por componente.
Ponto colorido e nome	A cor resume a saúde. Nomes longos podem aparecer cortados; passe o ponteiro sobre o nome para ver o completo.
Ver detalhes completos	Retorna à tela Monitor.

2 Visão geral do Monitor




Figura 2. Monitor real com a Production em estado Com problema.

Leia a tela da esquerda para a direita: entrada de mensagens, processamento e saída. Cada cartão representa um componente configurado, também chamado de host. Neste contexto, host não significa necessariamente um servidor físico.

Como ler o exemplo

Na captura, FileIncidentService tem 17 mensagens; IncidentRouterProcess, 53; FileOutputOperation, 26; PriorityOutputOperation, 10. Todas as filas e os contadores de erros recentes estão zerados. Ainda assim, todos os cartões estão unavailable porque a Production monitorada não está em execução normal.

Essas contagens não devem ser somadas para obter o número de incidentes. Uma mensagem participa de mais de um componente, e o histórico pode incluir respostas entre eles.

O Monitor atualiza a cada 10 segundos. A barra lateral das outras telas é coletada quando a página é carregada; ela não é atualizada continuamente enquanto você lê uma análise longa.

3 Campos e indicadores do Monitor

Campo ou elemento	O que representa e como usar
Production	Nome exato da Production acompanhada: Guardian.Production.GuardianProduction. Não existe seletor de Production nesta interface.
Estado	Texto retornado pelo IRIS, como Com problema. Descreve a Production inteira; difere do selo de saúde de cada host.
Coletado em	Data e hora do servidor IRIS em que os dados foram consultados. A interface não mostra o fuso nem faz conversão para o horário do navegador.
Atualiza a cada 10s	Intervalo de recarregamento automático da tela principal do Monitor.
Hosts de entrada (Service)	Componentes que recebem dados para iniciar o fluxo.
Hosts de processamento (Process)	Componentes que tratam e encaminham as mensagens.
Hosts de saída (Operation)	Componentes que entregam dados ao destino.
Nome no cartão	Nome do item configurado na Production. Use o mesmo nome ao selecionar um componente no Investigator.
Selo de saúde	Resultado das regras de unavailable, unknown, degraded e healthy, explicadas na próxima página.
Fila	Quantidade pendente na fila consultada naquele instante. Zero não prova que todo processamento foi concluído com sucesso.
Mensagens	Quantidade de cabeçalhos de mensagem ainda registrados em que o host aparece como origem ou destino. É histórico acumulado, não taxa nem total da janela do Investigator.
Erros recentes	Quantidade de cabeçalhos com erro envolvendo o host e criados nos últimos 900 segundos, equivalentes a 15 minutos.
Tendência de fila	Até 10 amostras persistidas, da mais antiga para a mais recente. Por exemplo, 7, 3, 0 indica redução da fila.
Travado	Selo adicional: as últimas três amostras têm fila positiva e sem diminuir. Indica acúmulo; não confirma um processo do sistema operacional travado.

As amostras são gravadas quando o coletor é chamado. Uma navegação pode gerar mais de uma coleta; três amostras não equivalem obrigatoriamente a 30 segundos. Não há coletor independente agendado nesta versão.

4 Estados e componentes do fluxo

As regras são aplicadas nesta ordem. A primeira condição atendida determina o selo do cartão.

Estado	Regra e interpretação
1 unavailable	A Production esperada não está em execução ou o componente está desabilitado. Verifique primeiro o estado geral e depois a configuração do host.
2 unknown	Production em execução e host habilitado, mas sem mensagens no histórico disponível. Ainda não há base de tráfego para classificá-lo como saudável.
3 degraded	Host habilitado, Production em execução e histórico existente; há fila positiva ou erro nos últimos 15 minutos.
4 healthy	Host habilitado, Production em execução, histórico existente, fila zerada e nenhum erro recente.

Um erro já resolvido pode manter degraded até sair da janela de 15 minutos. O selo não prova uma falha ativa. Da mesma forma, healthy não é uma verificação direta de todos os processos e destinos externos.

O papel dos quatro componentes

Nome abreviado	Função na definição do projeto
FileIncidentService	Recebe arquivos .txt em /durable/guardian/in e usa /durable/guardian/archive para arquivamento.
IncidentRouterProcess	Trata a mensagem de incidente e aplica a regra de roteamento por severidade.
FileOutputOperation	Grava a saída normal em /durable/guardian/out.
PriorityOutputOperation	Grava a saída priorizada em /durable/guardian/out_priority. Na regra do projeto, recebe MEDIUM, HIGH e CRITICAL; os demais valores seguem para a saída normal.

Os caminhos pertencem ao ambiente do IRIS. A definição carregada no Portal pode ter alterações; consulte a configuração efetiva antes de operar. PublicHealthProduction é outra Production e não é acompanhada por este Monitor.

5 Preencher uma investigação

Figura 3. Formulário inicial do AI Incident Investigator.

Campo ou elemento	O que representa e como usar
Componente	Lista dos hosts da Production monitorada. Selecione o nome visto no cartão; o tipo aparece entre parênteses.
Selecione...	Opção inicial sem componente escolhido. Selecione um item para obter resultado.
Janela (minutos)	Período retrospectivo dos eventos, contado a partir da consulta. O padrão da tela é 60 minutos; o formulário aceita no mínimo 1.
Investigar	Coleta saúde atual, até 20 mensagens recentes da janela e documentação relacionada; solicita uma análise à IA.
Investigando...	Estado temporário do botão após o envio. O botão fica desabilitado enquanto a solicitação é processada.
Coletando evidência e analisando com IA...	Indica processamento em andamento. Aguarde o resultado para evitar consultas repetidas.

Exemplo de uso

1. Abra Investigator.
2. Escolha Guardian.Operation.FileOutputOperation.
3. Mantenha 60 minutos para examinar a última hora.
4. Clique em Investigar.
5. Leia Saúde atual e Eventos na janela antes de avaliar a Análise.

Para ampliar a busca, use por exemplo 1440 minutos para um dia. A janela altera os eventos recuperados; não altera o histórico de Mensagens nem a janela fixa de 15 minutos de Erros recentes.

A investigação não inicia, para, habilita ou corrige componentes. O resultado é salvo para consulta contextual pelo RAG; esta interface ainda não oferece uma lista navegável de investigações anteriores.

6 Interpretar o resultado da investigação




Figura 4. Resultado real para FileOutputOperation, com janela de 60 minutos.

Campo ou elemento	O que representa e como usar
Saúde atual	Repete a classificação e as métricas do coletor do Monitor: selo, Fila, Mensagens e Erros recentes.
Eventos na janela (N)	Número de mensagens recuperadas para o componente no período. São no máximo 20, da mais recente para a mais antiga; não é necessariamente o total do período.
Nenhum evento registrado nesta janela	Nenhuma mensagem correspondente foi recuperada no intervalo. Não significa que o componente nunca tenha processado dados.
msg # e data/hora	Quando há eventos, mostra o identificador do cabeçalho de mensagem e o momento de criação.
Origem → destino	Mostra quem enviou e quem recebeu a mensagem. Permite localizar o trecho do fluxo envolvido.
sucesso ou texto de erro	Apresenta a interpretação do status do cabeçalho. O erro legível ajuda a buscar a causa e a documentação correspondente.

A lista de eventos vem do histórico de mensagens. Ela não substitui o Log de Eventos completo do Portal IRIS. Na captura, N = 0 e Mensagens = 26 são compatíveis: há histórico, mas nenhum registro na última hora.

7 Análise e documentação relacionada

DOCUMENTAÇÃO RELACIONADA

Fase 4 - AI Incident Investigator

similaridade: 0.795

Investigação de `Guardian.Operation.FileOutputOperation` contra o histórico real do experimento de falha/recuperação da Fase 1 (janela grande o suficiente para cobrir os dados de 09/09/2026):

Figura 5. Documentação recuperada para apoiar a investigação.

Campo ou elemento	O que representa e como usar
Análise	Texto gerado por IA a partir da saúde, eventos e documentos recuperados. Pode conter interpretações incorretas; confirme com os dados mostrados.
Resumo e observações	Resumo do caso e fatos que o modelo identifica na evidência.
Hipóteses	Possíveis explicações. Não equivalem a causa confirmada.
Lacunas	Informações que faltam para concluir o diagnóstico.
Próximos passos sugeridos	Ações de verificação propostas. Nenhuma é executada automaticamente.
Documentação relacionada	Trechos da base indexada selecionados para apoiar o caso. Se não houver resultados, a tela informa isso.
Título da fonte	Nome do documento de origem do trecho.
Fonte entre parênteses	Identificador ou nome do arquivo de origem. É uma referência textual, não necessariamente um link clicável.
similaridade	Pontuação de proximidade entre a busca e o trecho, mostrada com três casas decimais. Não é probabilidade de acerto da análise.
Texto da fonte	Trecho recuperado, que pode conter exemplos históricos. Um erro descrito ali não prova que o mesmo erro esteja acontecendo agora.

Atenção ao exemplo real: a análise chamou as métricas de “Últimos 60 min”. A regra correta é: Fila e saúde são atuais; Mensagens é acumulado; Erros recentes usa 15 minutos; apenas os eventos seguem os 60 minutos escolhidos.

8 Usar o RAG Assistant




Figura 6. RAG com contexto de uma investigação anterior que registrou erro de cota.

Campo ou elemento	O que representa e como usar
Contexto: última investigação	Bloco opcional que reaproveita a investigação mais recente salva no ambiente. Confira se corresponde ao caso que deseja consultar.
Componente	Host investigado no resultado salvo. Pode ser diferente daquele que você pretendia consultar agora.
janela e data/hora	Período usado na investigação e momento em que ela foi registrada; não indicam uma nova coleta de eventos.
Resumo no bloco	Exibe até 600 caracteres da análise. Há rolagem interna quando necessário. A consulta usa o texto completo salvo.
Pergunte sobre o projeto...	Campo da pergunta. Pode vir preenchido com uma sugestão baseada no componente da última investigação; você pode editá-la.
Perguntar	Envia a pergunta à IA com documentos recuperados e, quando presente, a última investigação.
Perguntando... e indicador de espera	Mostram que a consulta está em processamento. Só abrir a página com a sugestão não dispara a pergunta.

Exemplo: “O que significa unavailable no Monitor e quais verificações devo fazer antes de iniciar a Production?”
Faça perguntas específicas e confira as fontes antes de aplicar uma orientação.

9 Respostas e falhas do RAG

Não foi possível consultar o modelo de IA agora (Gemini generate HTTP 429: You exceeded your current quota, please check your plan and billing details. For more information on this error, head to: <https://ai.google.dev/gemini-api/docs/rate-limits>. To monitor your current usage, head to: <https://ai.dev/rate-limit>.
 * Quota exceeded for metric:
 generativelanguage.googleapis.com/generate_content_free_tier_requests, limit: 20, model: gemini-3.6-flash
 Please retry in 31.628833197s.). Tente novamente em instantes.

Figura 7. Consulta real retornou HTTP 429 do Gemini.

Campo ou elemento	O que representa e como usar
Resposta	Texto produzido com o contexto disponível. A interface apresenta a resposta após o envio; não é um chat com histórico completo de conversa.
Fontes usadas	Quando há resposta sem abstenção e fontes recuperadas, lista os trechos documentais. Título, arquivo, similaridade e texto têm o mesmo significado da página 8 deste manual.
Limiar 0.58	Referência da regra de abstenção por baixa similaridade. É uma heurística inicial, não uma garantia de qualidade ou percentual de confiança.
Não sei ou contexto insuficiente	Sem documentos suficientemente próximos e sem investigação para apoiar a consulta, o sistema pode se abster. Reformule a pergunta ou reveja a base indexada.
Não foi possível consultar o modelo de IA agora	A chamada à IA falhou. A mensagem exibe o erro real; isso não significa automaticamente que a Production parou.
HTTP 429 e quota exceeded	No exemplo, o provedor informa limite de uso excedido. Verifique a cota com o responsável pela integração; siga a orientação de nova tentativa apresentada pelo serviço.

Quando existe investigação salva, o RAG pode responder apoiado nela mesmo sem documentos acima do limiar. Assim, a ausência de “Fontes usadas” não deve ser interpretada isoladamente como ausência de qualquer contexto.

A frase do rodapé sobre não inventar informações descreve o comportamento pretendido. Confira a resposta: a IA pode errar ou reproduzir uma interpretação inadequada de uma investigação anterior.

10 A opção novo modelo




Figura 8. Segunda opção de RAG disponível no menu.

Nesta edição, RAG Assistant (novo modelo) é uma segunda página que utiliza a mesma consulta e o mesmo provedor Gemini da opção principal. O rodapé informa que o segundo provedor ainda não foi escolhido.

Campo ou elemento	O que representa e como usar
Título e menu selecionado	Identificam a segunda página. Não comprovam uma troca de modelo.
Contexto da investigação	Usa a mesma última investigação salva no ambiente.
Pergunta e botão Perguntar	Funcionam como na opção Gemini, incluindo sugestão automática e envio explícito.
Resposta e Fontes usadas	Seguem as mesmas regras de geração, recuperação e abstenção.
Rodapé do segundo provedor	Explica que a opção é provisória e compartilha o backend atual.

Trocar para essa opção não é uma solução para a cota esgotada do Gemini. A indisponibilidade do mesmo provedor pode afetar ambas as páginas. Use a opção principal como referência de operação até que um provedor alternativo seja efetivamente configurado.

11 Roteiro para unavailable

1. Abra Monitor e confirme o nome da Production, o Estado e o horário de coleta. Se todos os hosts estiverem unavailable, comece pelo estado geral. Se apenas um estiver indisponível, confira também se ele está habilitado.
2. Abra o Portal de Administração em <http://localhost:53773/csp/sys/UtilHome.csp>. Selecione GUARDIAN e acesse Interoperabilidade → Configurar → Production. Confira Guardian.Production.GuardianProduction.
3. Consulte o Log de Eventos e o estado dos componentes para identificar por que a Production está Com problema. O Monitor não revela sozinho a causa desse estado. Iniciar, parar e habilitar são ações administrativas no Portal.
4. No Investigator, selecione o componente afetado e a janela que abrange o problema. Revise os eventos e os trechos documentais. Caso não haja eventos, amplie o intervalo e consulte os logs do Portal.
5. No RAG, confirme o componente e o horário da última investigação, escreva uma pergunta específica e valide a orientação com as fontes. Falha da IA não impede a leitura dos dados já apresentados.
6. Depois de uma correção operacional, retorne ao Monitor e acompanhe o estado geral, a fila e as mensagens. Erros recentes podem manter degraded por até 15 minutos; não reenvie mensagens apenas para mudar a cor do cartão.

Cuidados de leitura

Uma tela aberta prova acesso à aplicação, não execução da Production. Fila zero não comprova entrega. Documento de experimento não é evento atual. Similaridade não é confiança. Amostras não têm intervalo necessariamente uniforme. Atualizar uma URL que contém a pergunta ou os parâmetros da investigação pode executar a consulta novamente.

Referências e versão

Telas capturadas em 12/09/2026 no ambiente local. Definições conferidas em Guardian.UI.MonitorPage, InvestigatorPage, RAGPage, RAGAltPage e Shared; regras em Guardian.Monitor.StatusCollector, Guardian.Investigator.EvidenceCollector e Guardian.RAG.Query; fluxo em GuardianProduction e IncidentRoutingRule.

Arquivos do projeto: src/Guardian/UI; src/Guardian/Monitor/StatusCollector.cls; src/Guardian/Investigator/EvidenceCollector.cls; src/Guardian/RAG/Query.cls. O comportamento documentado deve ser revisto quando essas classes ou a configuração da Production forem alteradas.